Sprawozdanie 1

Analiza szeregów czasowych

Mateusz Wizner 277508

16 listopad 2025

Spis treści

Wprowadzenie **2**

Zadanie 3: Testowanie białoszumowości **2**

Zadanie 3a) - Implementacja testów białoszumowości 2

Podstawy teoretyczne 2

Przygotowanie danych 3

Test graficzny 3

Testy formalne 4

Zadanie 3b) - Symulacje porównawcze 5

Część I: Porównanie rozmiaru testu dla białego szumu 5

Część II: Szeregi niespełniające założenia białego szumu 5

Podsumowanie porównania testów 8

Zadanie 4: Dekompozycja szeregów czasowych **10**

Wybór szeregu i wstępna analiza 10

Dekompozycja na podstawie ruchomej średniej (decompose) 14

Dekompozycja na podstawie modelu regresji (tslm) 18

Model z trendem liniowym 18

Model z trendem kwadratowym 19

Porównanie dopasowania modeli 21

Model z transformacją Box-Cox 21

Dekompozycja STL 24
Model z sezonowością okresową 24
Model z sezonowością zmienną w czasie 25
Model z silnym wygładzaniem trendu 26
Eliminacja trendu i sezonowości przez różnicowanie 28
Porównanie wszystkich metod 30
Wnioski końcowe 32
Ocena jakości dekompozycji 32
Stacjonarność reszt 33
Transformacja Box-Cox 33
Wybór metody w praktyce 34

Podsumowanie **35**

Bibliografia i źródła **37**

Wprowadzenie

Niniejsze sprawozdanie zawiera rozwiązania zadań 3 i 4 z listy 1.

Zadanie 3: Testowanie białoszumowości

Zadanie 3a) - Implementacja testów białoszumowości

Zadanie 3a) wymaga implementacji i ilustracji działania graficznego oraz formalnych testów statystycznych weryfikujących hipotezę, że obserwowany szereg czasowy jest szeregiem typu biały szum (white noise).

Podstawy teoretyczne

Biały szum (WN) to ciąg zmiennych nieskorelowanych o średniej 0 i stałej wariancji σ^2. Teoretyczna funkcja autokorelacji $\rho(h)$ dla białego szumu wynosi zero dla każdego $h \neq 0$.

Dla szeregu IID, próbkowe autokorelacje $\hat{\rho}(k)$ są w przybliżeniu niezależnymi zmiennymi losowymi o rozkładzie normalnym ze średnią 0 i wariancją $1/n$. Asymptotyczne 95% przedziały istotności wynoszą: $\pm 1.96/\sqrt{n}$.

Przygotowanie danych

Parametry symulacji:
Długość szeregu (n): 100
Poziom istotności (α): 0.05
Maksymalne opóźnienie ($h_{\max}$): 25

Test graficzny

Test graficzny polega na ocenie próbkowej funkcji autokorelacji (ACF). Dla białego szumu asymptotycznie oczekujemy, że około 95% próbkowych autokorelacji $\hat{\rho}(k)$ będzie mieścić się w przedziale $\pm 1.96/\sqrt{n}$. Szereg można uznać za realizację białego szumu, jeśli:

1. Zdecydowana większość autokorelacji próbkowych mieści się w asymptotycznych przedziałach ufności
2. Brak systematycznych wzorców wykraczających poza te przedziały

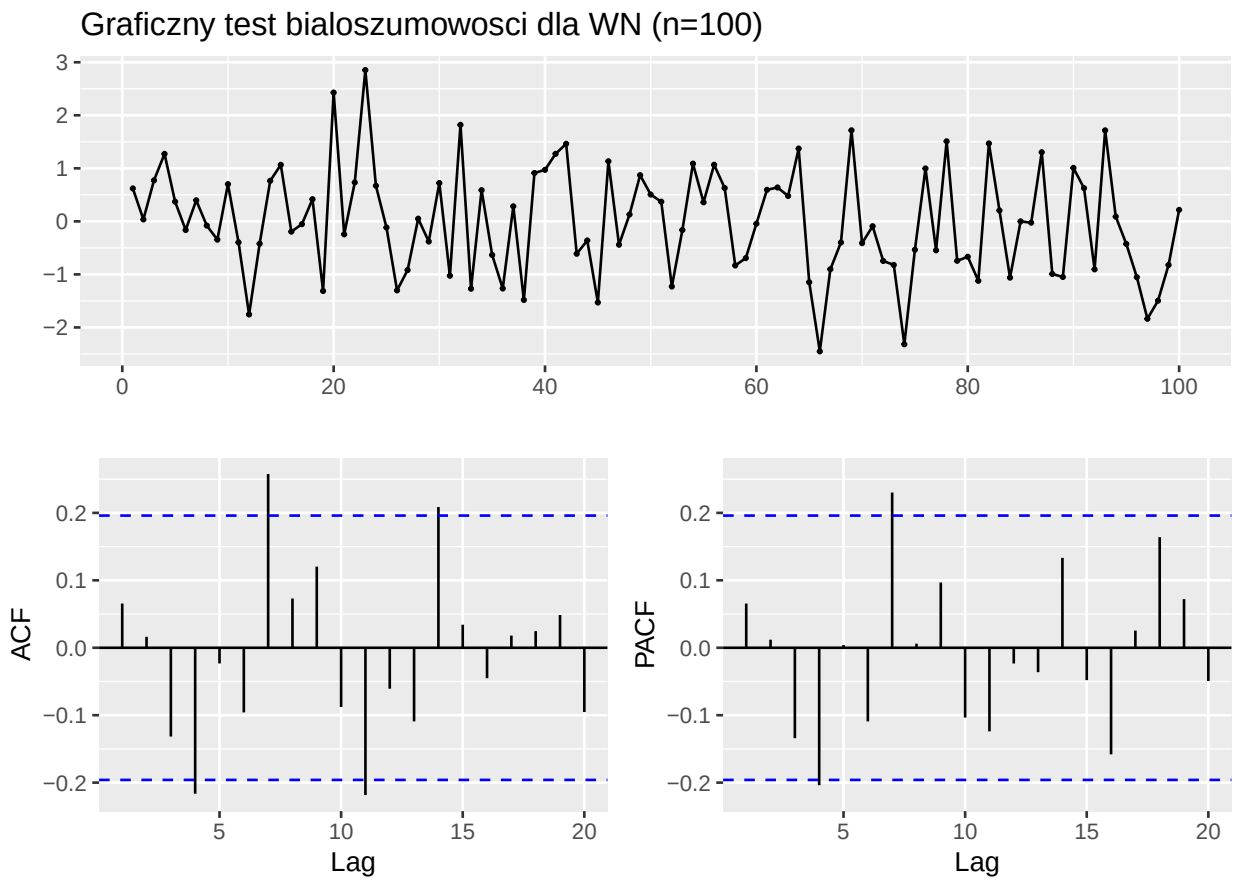

Rysunek 1: Graficzny test białoszumowości - wykres szeregu, ACF i PACF

Interpretacja: Na wykresie ACF widoczne jest, że zdecydowana większość słupków znajduje się w obrębie niebieskich przerywanych linii (asymptotycznych przedziałów ufności). Słupki reprezentują próbkowe autokorelacje, które są bliskie zeru, co wizualnie potwierdza, że szereg może być traktowany jako biały szum.

Testy formalne

Formalne testy statystyczne weryfikują hipotezę zerową H_0, że obserwowane autokorelacje są jednocześnie równe zero aż do opóźnienia h_{max}.

— **Formalne testy statystyczne** —

Maksymalne opóźnienie (lag) $h_{\max} = 25$

Wynik testu Boxa-Pierce'a

```
##
##  Box-Pierce test
##
## data:  WN_ts
## X-squared = 32.574, df = 25, p-value = 0.1421
```

Wynik testu Ljunga-Boxa

```
##
##  Box-Ljung test
##
## data:  WN_ts
## X-squared = 37.179, df = 25, p-value = 0.05552
```

Wynik testu Ljunga-Boxa dla $h_{\max} = 1$

```
##
##  Box-Ljung test
##
## data:  WN_ts
## X-squared = 0.44242, df = 1, p-value = 0.506
```

Interpretacja

Test Boxa-Pierce'a p-value $= 0.1421 > \alpha = 0.05$ – brak podstaw do odrzucenia H_0

Test Ljunga-Boxa p-value $= 0.0555 > \alpha = 0.05$ – brak podstaw do odrzucenia H_0

Ponieważ wygenerowany szereg jest realizacją białego szumu,
oczekujemy wysokich wartości p-value, co oznacza brak podstaw
do odrzucenia hipotezy zerowej o białoszumowości.

Zadanie 3b) - Symulacje porównawcze

Zadanie 3b) wymaga przeprowadzenia symulacji komputerowych mających na celu porównanie skuteczności graficznego testu białoszumowości z formalnymi testami statystycznymi.

Część I: Porównanie rozmiaru testu dla białego szumu

W pierwszej kolejności porównamy, jak często testy formalne odrzucają prawdziwą hipotezę zerową.

Symulacja dla 30 obserwacji, z maksymalnym opóźnieniem 7.

Rozkład Normalny

Empiryczny rozmiar testu Boxa-Pierce'a: 0.028

Empiryczny rozmiar testu Ljunga-Boxa: 0.072

Rozkład wykładniczy (po przesunięciu do średniej 0)

Empiryczny rozmiar testu Boxa-Pierce'a: 0.011

Empiryczny rozmiar testu Ljunga-Boxa: 0.04

Wnioski: Test Ljung-Boxa ma rozmiar bliższy nominalnemu poziomowi $\alpha = 0.05$, szczególnie dla małych n, w porównaniu do testu Boxa-Pierce'a.

Część II: Szeregi niespełniające założenia białego szumu

A. Model MA(1) z małą korelacją

Model ruchomej średniej rzędu 1 (MA(1)) ma teoretyczną autokorelację zerową dla opóźnień $h \geq 2$. Użycie małego parametru $\theta = 0.1$ sprawi, że korelacja będzie niewielka.

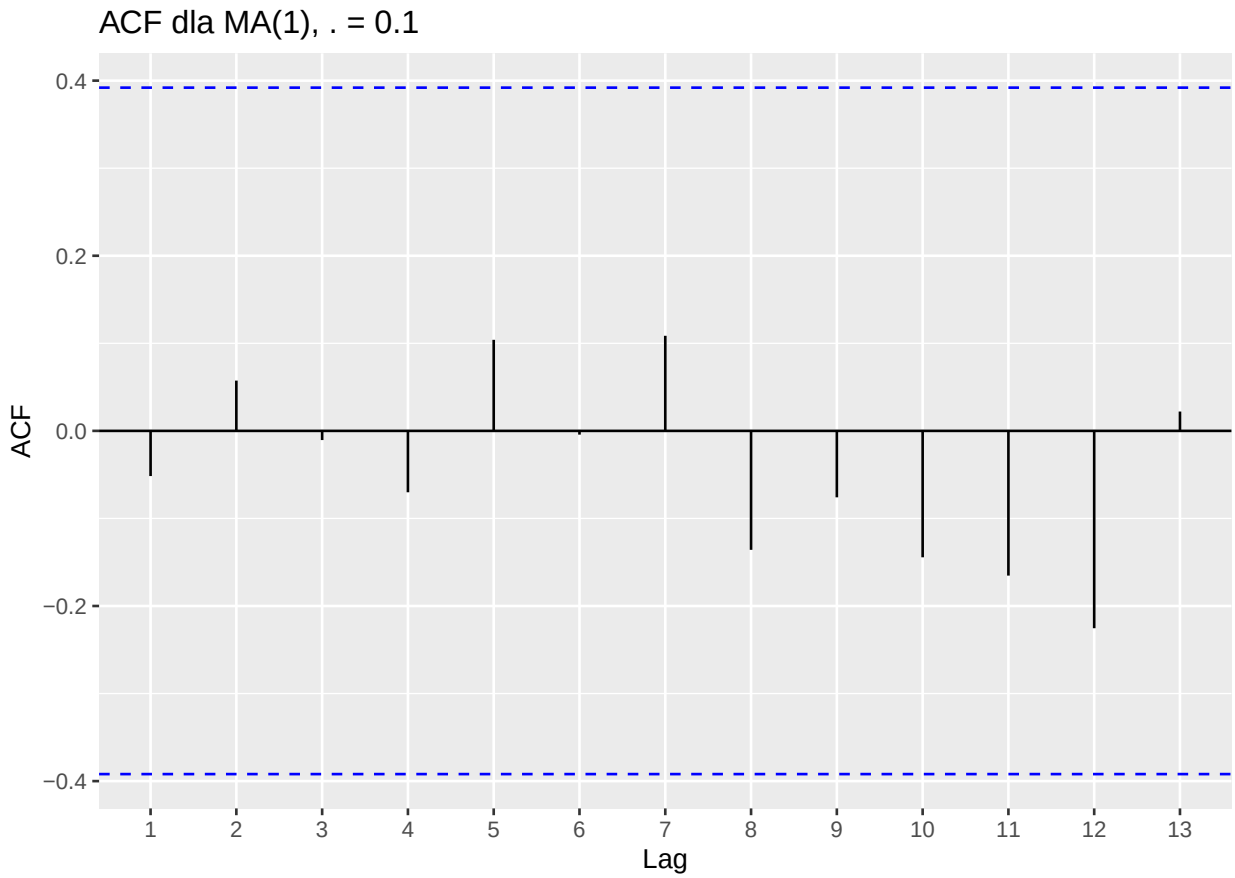

Testy dla $h_{\max} = 6$

```
##
##  Box-Ljung test
##
## data:  MA1
## X-squared = 0.69875, df = 6, p-value = 0.9945
```

Interpretacja: Dla małego n i małej korelacji ($\theta = 0.1$), test graficzny może nie wykazać znaczącego przekroczenia granic dla $h = 1$, a formalne testy mogą nie odrzucić H_0 (niska moc testu dla małych próbek i małej korelacji).

B. Błądzenie losowe (Random Walk)

Błądzenie losowe nie jest szeregiem stacjonarnym, a jego ACF zanika bardzo powoli. Testy białoszumowości powinny zdecydowanie odrzucić H_0.

Testy dla $h_{\max} = 12$

```
##
##  Box-Ljung test
##
## data:  RW
## X-squared = 227.58, df = 12, p-value < 2.2e-16
```

Interpretacja: Test graficzny i formalny zgodnie odrzucają H_0 o białoszumowości, ponieważ błądzenie losowe wykazuje silną, powoli zanikającą autokorelację, charakterystyczną dla niestacjonarnych szeregów z trendem.

C. Szereg z trendem deterministycznym

Szereg $X_t = m_t + WN_t$, gdzie m_t jest trendem liniowym, również jest niestacjonarny, a jego ACF zanika powoli i dodatnio.

Szereg z trendem liniowym + biały szum

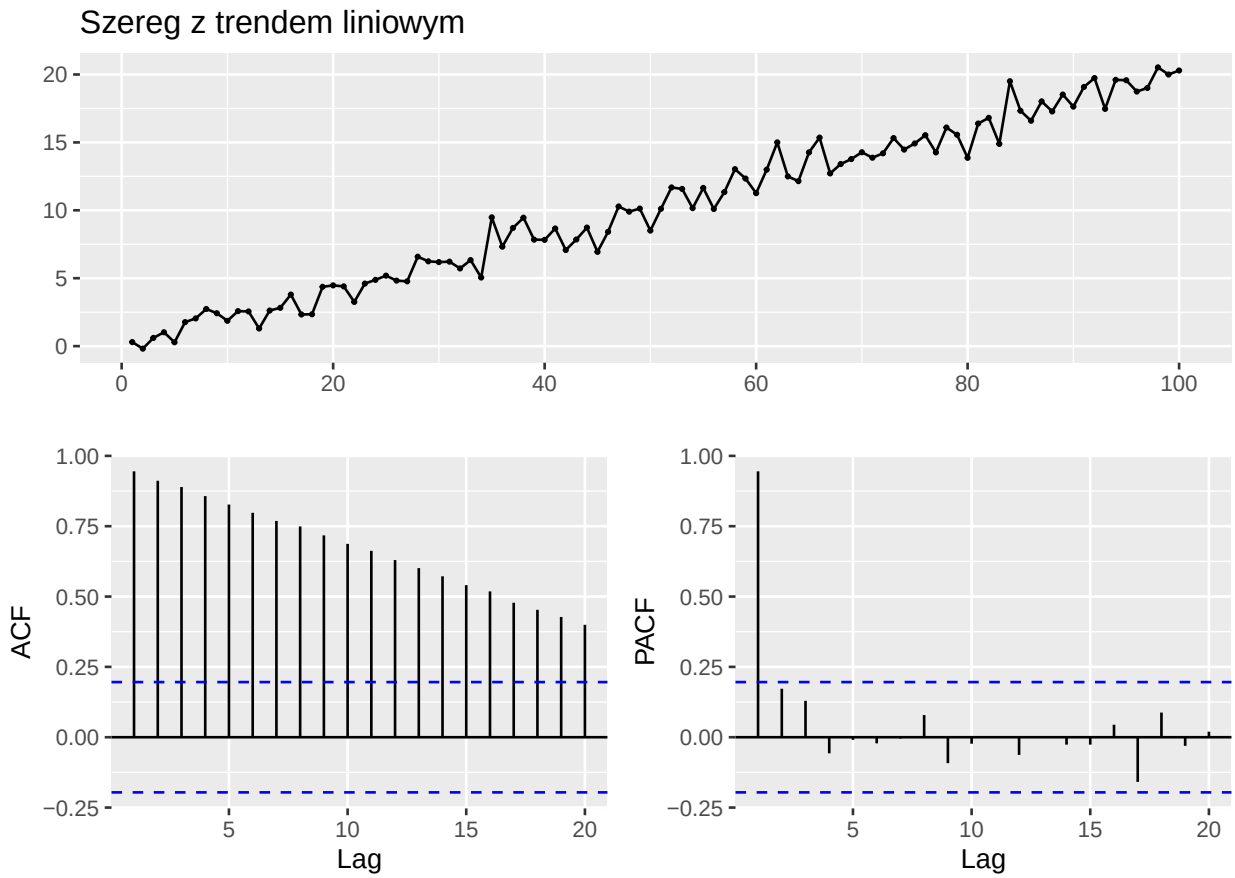

Testy dla $h_{\max} = 25$

```
##
##  Box-Ljung test
##
## data:  szereg1
## X-squared = 1134.4, df = 25, p-value < 2.2e-16
```

Interpretacja: Zarówno ACF (wykres) jak i test formalny (niskie p-value) wskazują na istotną zależność, potwierdzając, że szereg nie jest białym szumem.

Podsumowanie porównania testów

Kluczowe różnice obserwowane w symulacjach:

1. Rozmiar testów

Dla $n = 30$ i $h_{\max} = 7$:

- **Rozkład normalny**:
  Box–Pierce ma wyraźnie zaniżony rozmiar (0.028),
  Ljung–Box zawyżony (0.072).

- **Rozkład wykładniczy**:
  Box–Pierce bardzo konserwatywny (0.011),
  Ljung–Box bliżej nominalnego poziomu 0.05 (0.04).

Wniosek:

Ljung–Box zwykle trafia bliżej $\alpha = 0{,}05$, choć przy małych próbach bywa liberalny.
Box–Pierce jest systematycznie konserwatywny, co obniża moc, ale dobrze kontroluje błąd I rodzaju.

2. Wpływ rozkładu

Rozkład wykładniczy powoduje silniejszą konserwatywność obu testów niż normalny.

3. Wpływ $h_{\mathbf{max}}$

- Zbyt małe $h_{\max}$ obniża moc.
- Zbyt duże względem n prowadzi do niestabilności i konserwatywności.

4. Metoda graficzna vs testy formalne

- **ACF**: szybka diagnoza rodzaju zależności; wskazuje charakter autokorelacji, ale wymaga subiektywnej interpretacji i bywa wrażliwa na pojedyncze skoki.
- **Testy formalne**: dostarczają obiektywnej oceny statystycznej, analizując pojedynczą statystykę opartą na ACF dla początkowych opóźnień.

5. Skuteczność wykrywania naruszeń

- Dla silnych odstępstw (trend, random walk) wszystkie metody jednoznacznie odrzucają H_0.
- Dla słabych zależności (np. MA(1) z $\theta = 0{,}1$) moc jest niska przy małych n.
- Moc rośnie wraz z długością szeregu i siłą autokorelacji.

Zadanie 4: Dekompozycja szeregów czasowych

Wybór szeregu i wstępna analiza

Do analizy wybrano **bezrobocie** z pakietu TSAFBook, który reprezentuje miesięczną stopę bezrobocia rejestrowanego w Polsce. Szereg ten charakteryzuje się nieregularnym trendem długoterminowym oraz wyraźną sezonowością roczną.

Podstawowe statystyki szeregu `bezrobocie`

- Okres: od 2000-1 do 2014-9
- Częstotliwość: 12 obserwacji na jednostkę czasu
- Liczba obserwacji: 177
- Średnia: $\mu = 14.62$
- Mediana: mediana = 13.8
- Odchylenie standardowe: $\sigma = 3.16$

Analiza graficzna

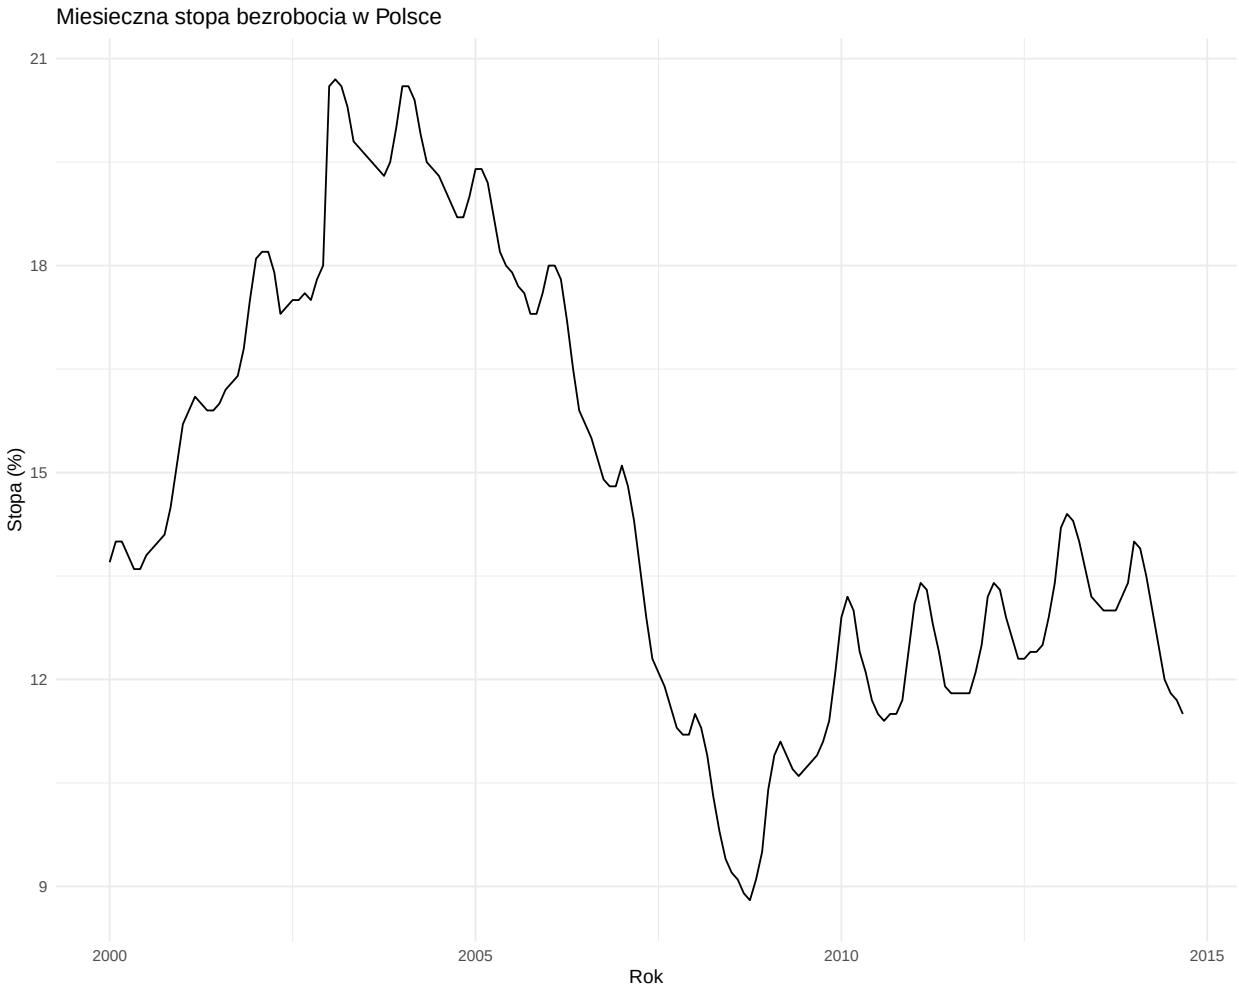

Rysunek 2: Wstępna analiza graficzna szeregu bezrobocie

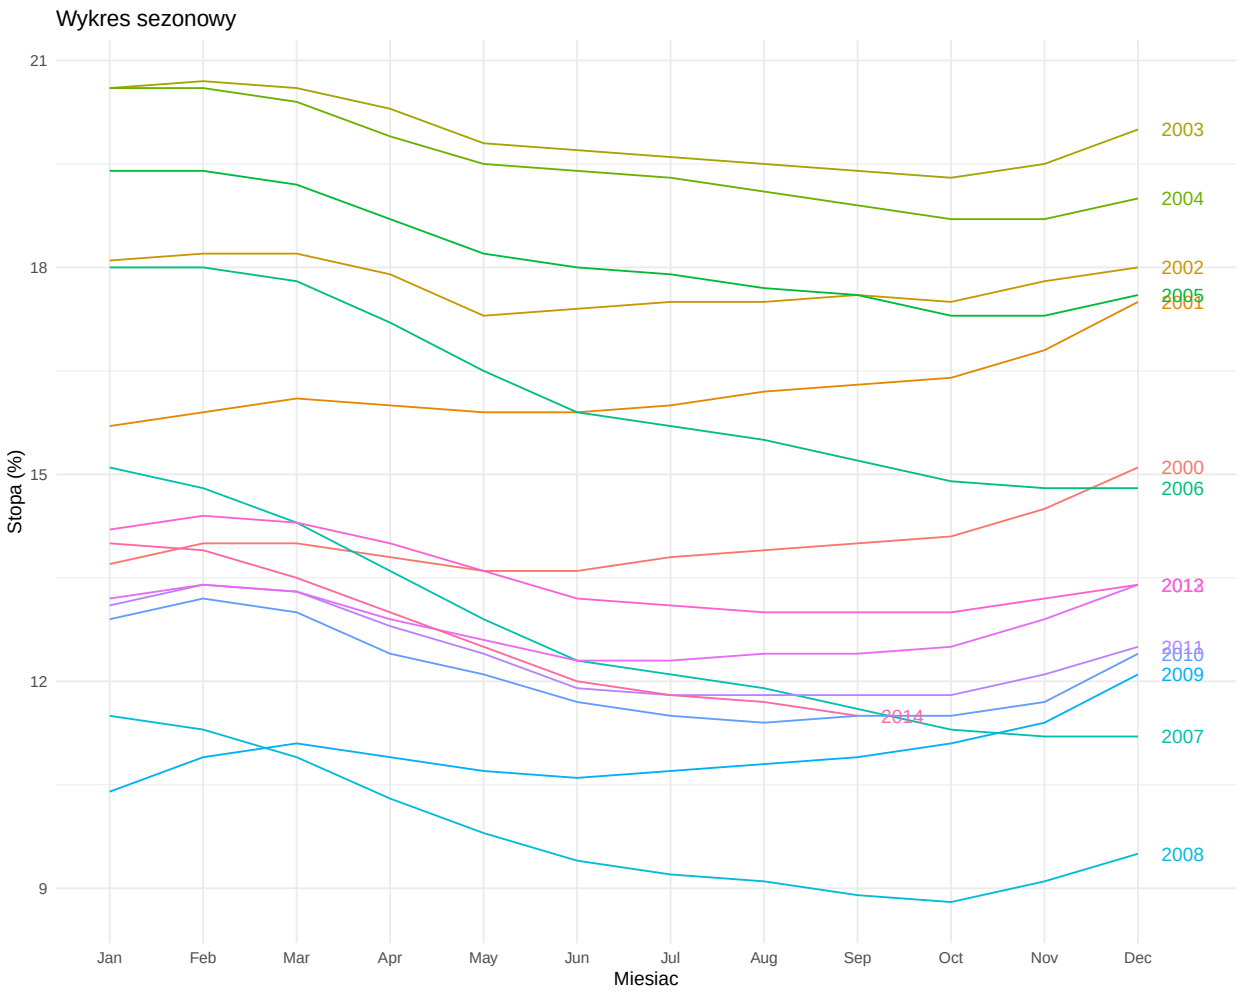

Rysunek 3: Wstępna analiza graficzna szeregu bezrobocie

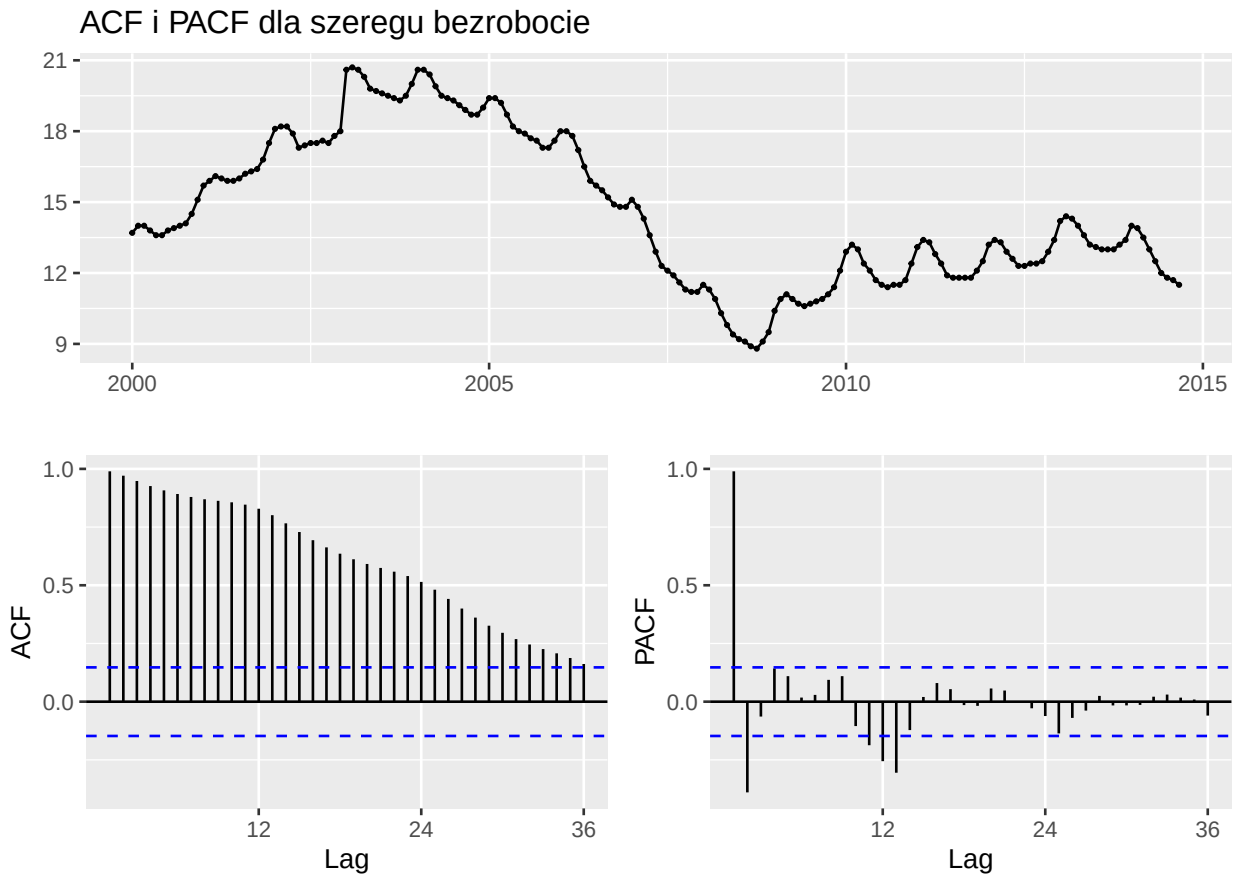

Rysunek 4: Funkcje ACF i PACF dla szeregu bezrobocie

Optymalne λ (Box-Cox): 1.02

Interpretacja:
λ bliskie 1 sugeruje, że szereg ma charakter addytywny
i transformacja Boxa-Coxa nie jest konieczna.
Mimo to, dla celów porównawczych, przetestowano również model z $\lambda = 0$ (logarytmizacja).

Wnioski z wstępnej analizy:

1. **Trend:** Widoczny jest nieregularny trend długoterminowy. Stopa bezrobocia osiągnęła szczyt około 2004 roku, następnie spadła, po 2008 roku ponownie wzrosła i zaczęła spadać.

2. **Sezonowość:** Wahania sezonowe (powtarzające się cykle roczne) są bardzo wyraźne. Najwyższa stopa bezrobocia występuje zimą (styczeń-luty), najniższa latem.

3. **Wariancja:** Amplituda wahań sezonowych i wariancja wokół trendu nie zmieniają się istotnie wraz z poziomem szeregu, co sugeruje preferowanie modelu addytywnego.

4. **ACF:** Funkcja autokorelacji zanika bardzo powoli i cyklicznie, co świadczy o obecności trendu długoterminowego i sezonowego oraz o niestacjonarności szeregu.

Dekompozycja na podstawie ruchomej średniej (decompose)

Model addytywny

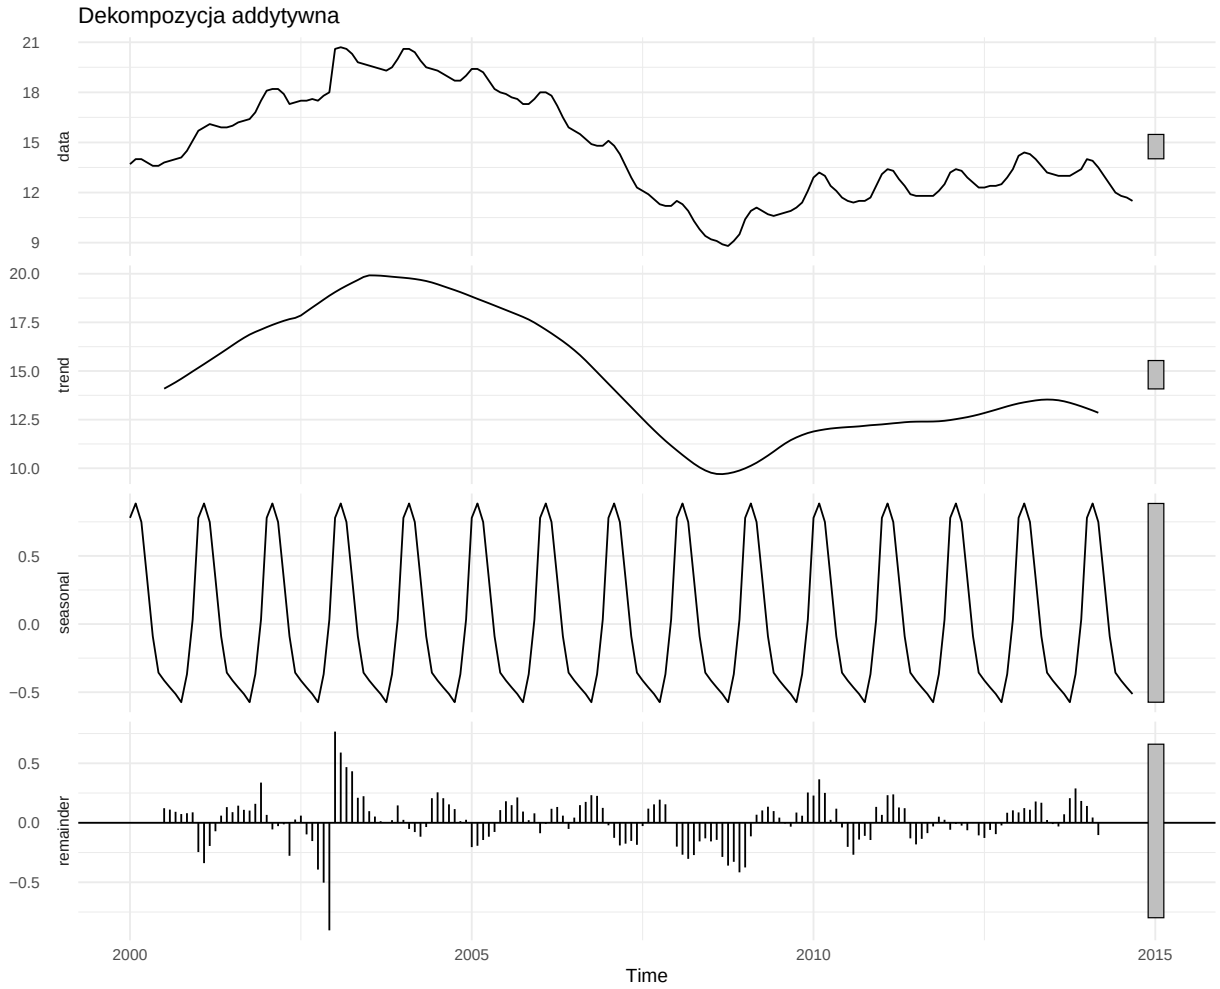

Rysunek 5: Dekompozycja addytywna (decompose)

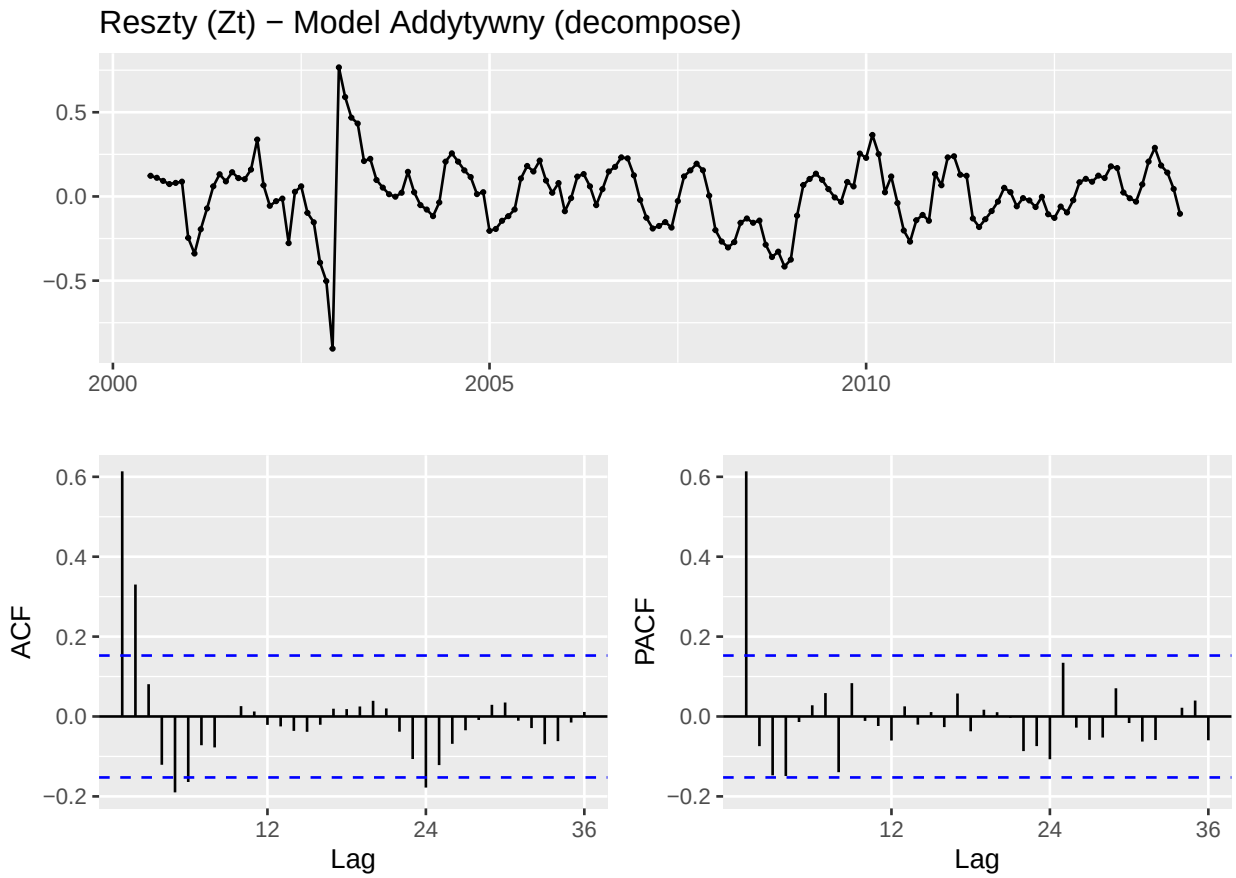

Rysunek 6: Analiza reszt - model addytywny

Model multiplikatywny

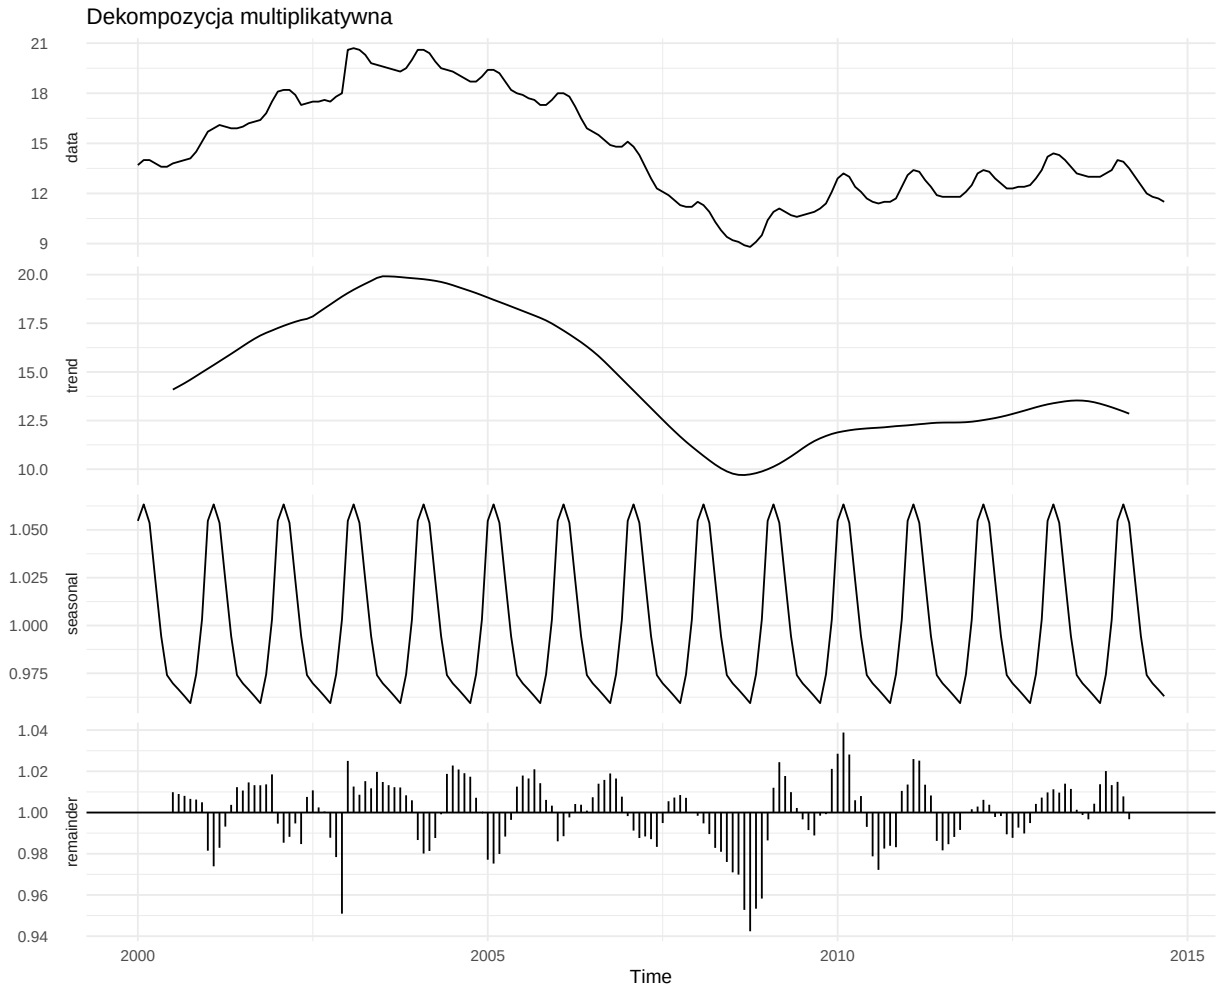

Rysunek 7: Dekompozycja multiplikatywna (decompose)

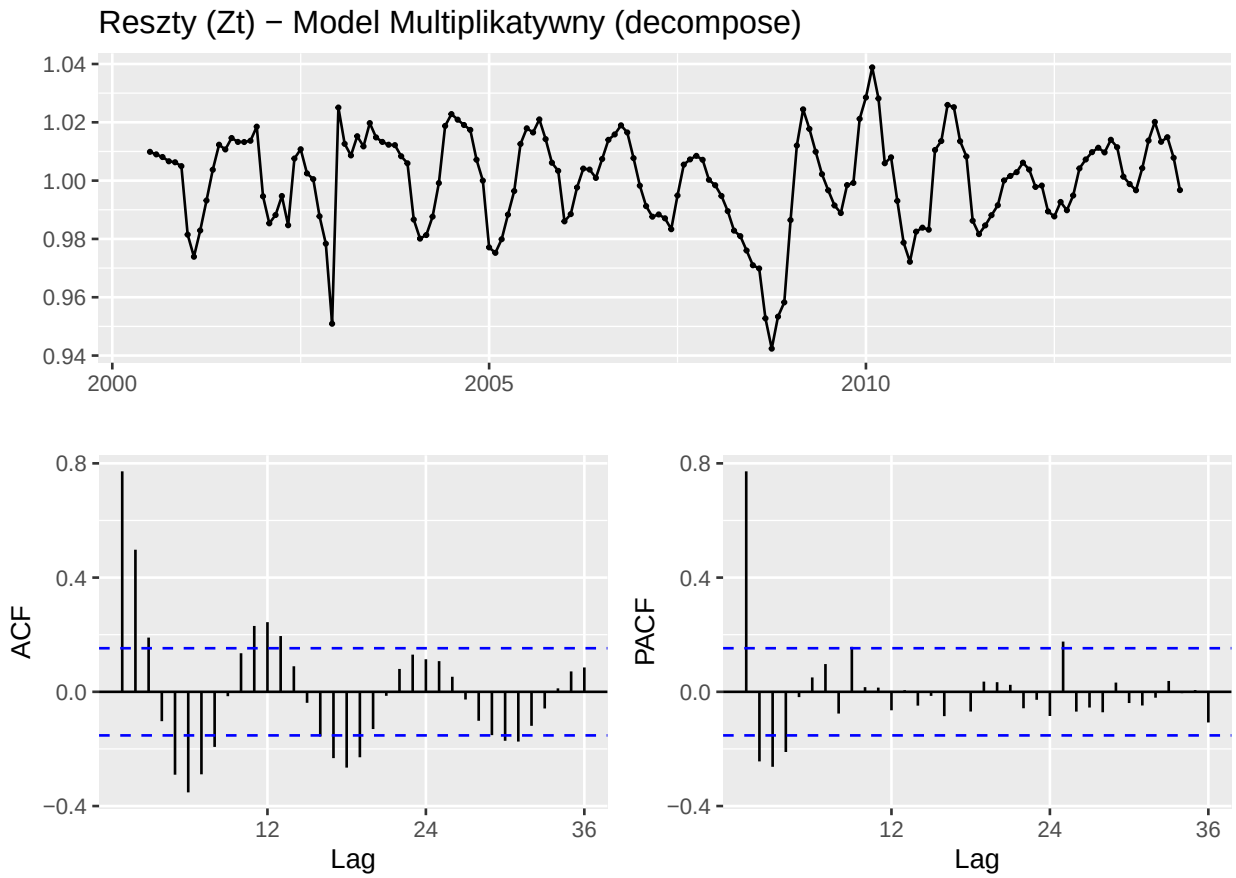

Rysunek 8: Analiza reszt - model multiplikatywny

Porównanie: Model addytywny dostarcza lepszych i bardziej stacjonarnych reszt (mniejsze wahania, jednorodna wariancja) niż model multiplikatywny, co potwierdza wnioski z analizy wstępnej o addytywnym charakterze szeregu.

Dekompozycja na podstawie modelu regresji (tslm)

Model z trendem liniowym

```
##
## Call:
## tslm(formula = bezrobocie ~ trend + season)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -4.8248 -1.8292  0.2425  1.7754  3.8798
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 18.562406   0.729670  25.439   <2e-16 ***
## trend       -0.037597   0.003745 -10.040   <2e-16 ***
## season2      0.144264   0.928561   0.155    0.877
## season3      0.041861   0.928584   0.045    0.964
## season4     -0.340543   0.928622  -0.367    0.714
## season5     -0.722946   0.928674  -0.778    0.437
## season6     -0.958682   0.928742  -1.032    0.303
## season7     -0.987752   0.928825  -1.063    0.289
## season8     -1.003488   0.928924  -1.080    0.282
## season9     -1.025891   0.929037  -1.104    0.271
## season10    -1.096733   0.945056  -1.160    0.248
## season11    -0.859136   0.945108  -0.909    0.365
## season12    -0.428682   0.945175  -0.454    0.651
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.543 on 164 degrees of freedom
## Multiple R-squared:  0.3974, Adjusted R-squared:  0.3533
## F-statistic: 9.011 on 12 and 164 DF,  p-value: 3.705e-13
```

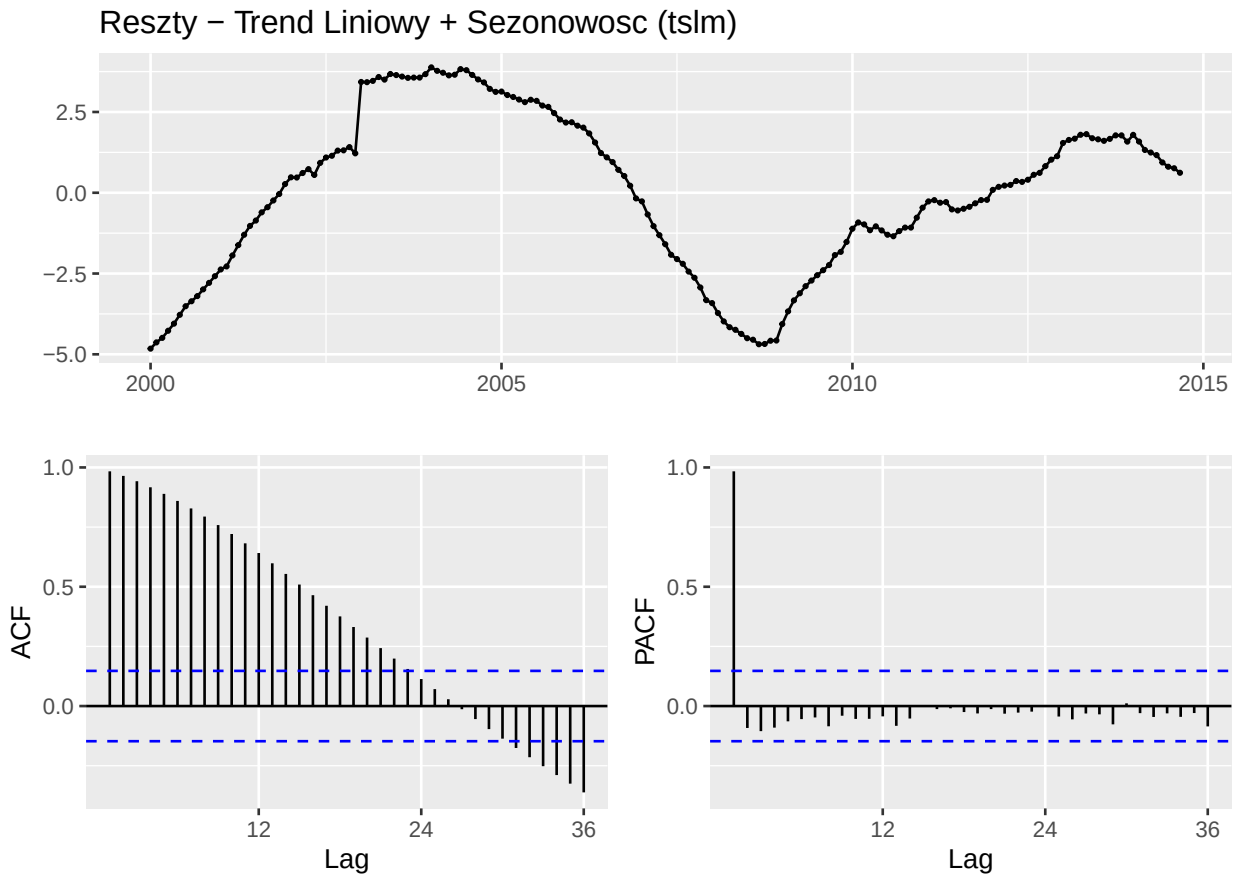

Rysunek 9: Reszty - trend liniowy + sezonowość

Model z trendem kwadratowym

```
##
## Call:
## tslm(formula = bezrobocie ~ trend + I(trend^2) + season)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -4.7613 -1.8579  0.2659  1.7651  3.8472
##
## Coefficients:
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1.841e+01  8.482e-01  21.703   <2e-16 ***
## trend       -3.233e-02  1.511e-02  -2.139   0.0339 *
## I(trend^2)  -2.959e-05  8.225e-05  -0.360   0.7195
## season2      1.441e-01  9.310e-01   0.155   0.8772
## season3      4.151e-02  9.311e-01   0.045   0.9645
## season4     -3.410e-01  9.311e-01  -0.366   0.7147
```

```
## season5     -7.234e-01  9.311e-01  -0.777   0.4383
## season6     -9.591e-01  9.312e-01  -1.030   0.3046
## season7     -9.881e-01  9.313e-01  -1.061   0.2903
## season8     -1.004e+00  9.314e-01  -1.078   0.2828
## season9     -1.026e+00  9.315e-01  -1.101   0.2724
## season10    -1.107e+00  9.480e-01  -1.168   0.2444
## season11    -8.699e-01  9.481e-01  -0.918   0.3602
## season12    -4.394e-01  9.482e-01  -0.463   0.6437
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.55 on 163 degrees of freedom
## Multiple R-squared:  0.3978, Adjusted R-squared:  0.3498
## F-statistic: 8.284 on 13 and 163 DF,  p-value: 1.084e-12
```

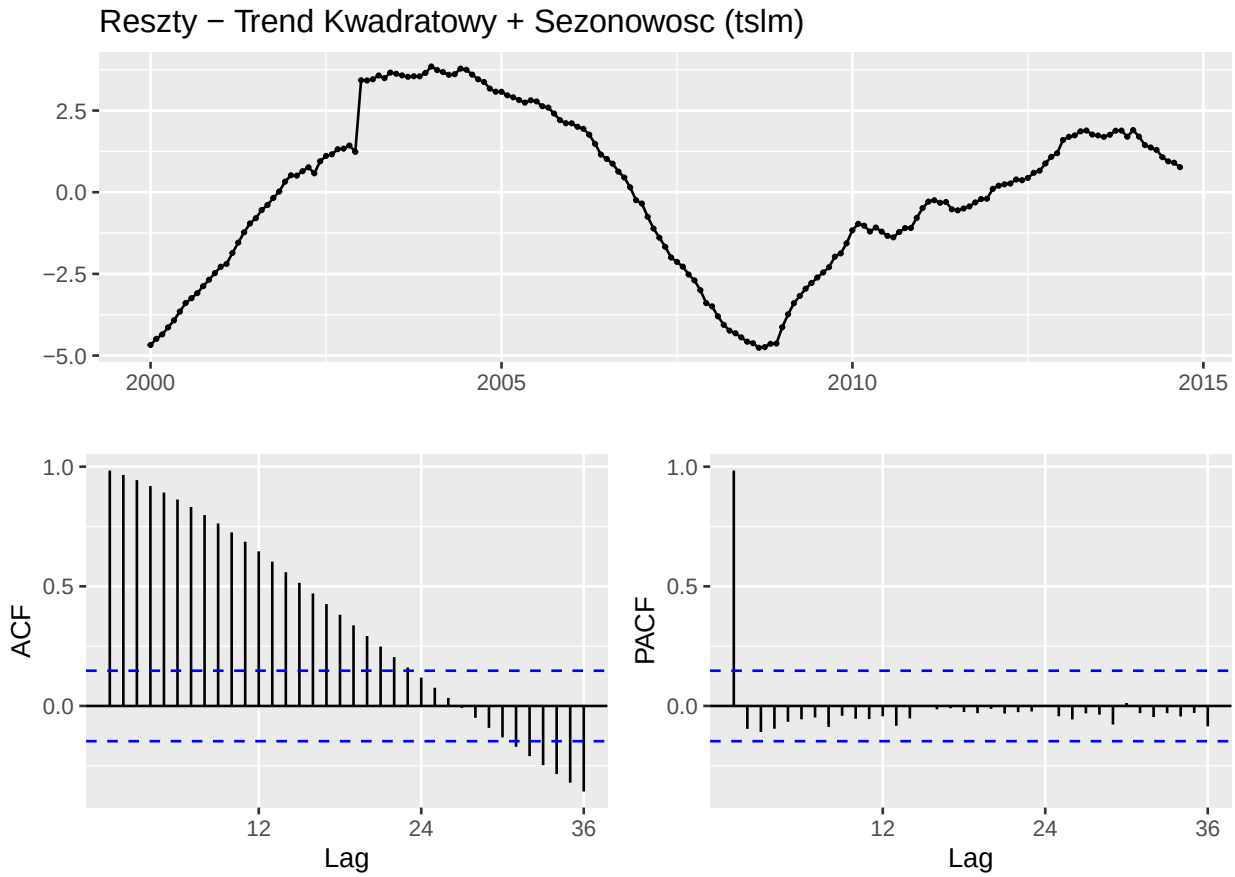

Rysunek 10: Reszty - trend kwadratowy + sezonowość

Porównanie dopasowania modeli

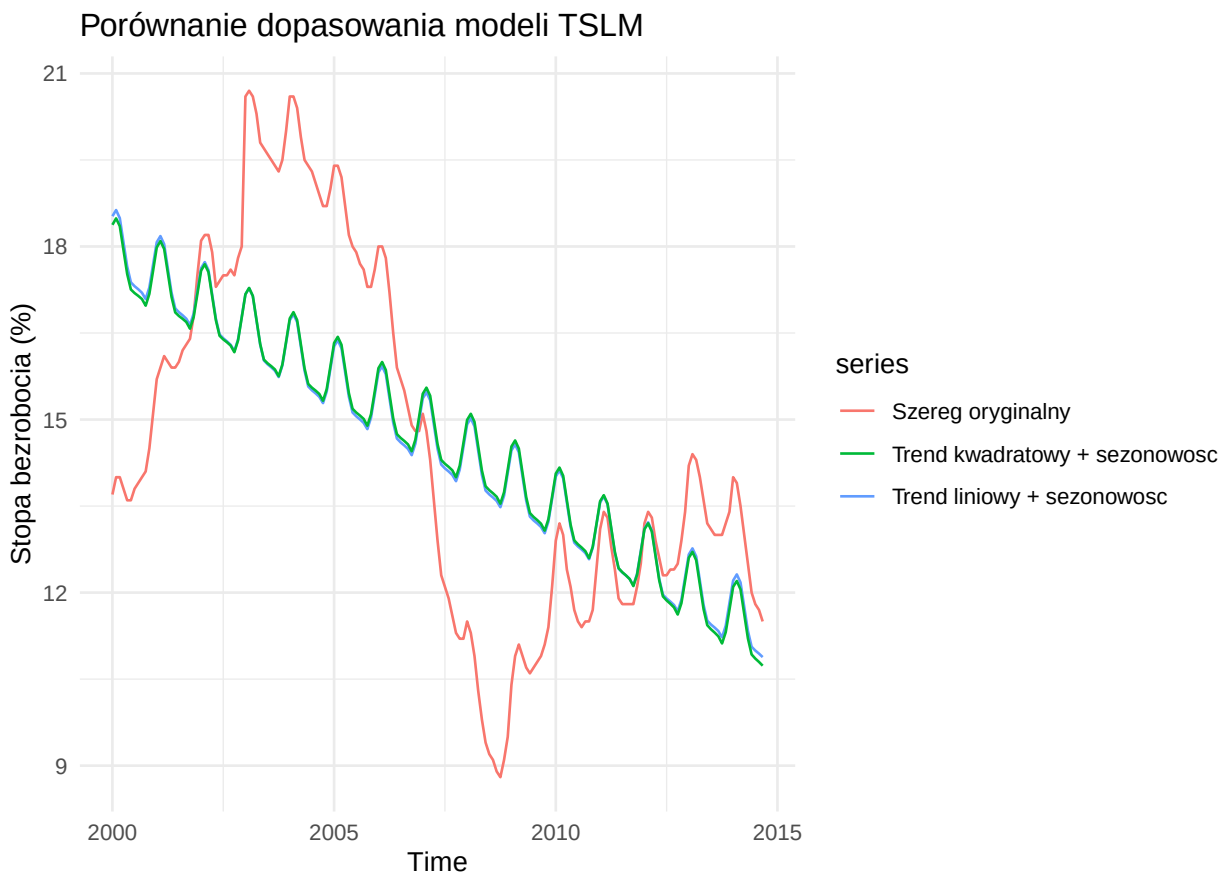

Rysunek 11: Porównanie modeli regresyjnych

Model z transformacją Box-Cox

```
##
## Call:
## tslm(formula = bezrobocie ~ trend + I(trend^2) + season, lambda = 0)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.39973 -0.11406  0.02608  0.12773  0.24771
##
## Coefficients:
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept)  2.940e+00  5.875e-02  50.045  < 2e-16 ***
## trend       -2.985e-03  1.047e-03  -2.851  0.00492 **
## I(trend^2)   2.542e-06  5.697e-06   0.446  0.65605
## season2      1.065e-02  6.449e-02   0.165  0.86903
```

```
## season3      3.711e-03  6.449e-02   0.058  0.95419
## season4     -2.291e-02  6.449e-02  -0.355  0.72285
## season5     -4.957e-02  6.450e-02  -0.769  0.44323
## season6     -6.843e-02  6.450e-02  -1.061  0.29031
## season7     -7.127e-02  6.451e-02  -1.105  0.27086
## season8     -7.242e-02  6.451e-02  -1.123  0.26328
## season9     -7.450e-02  6.452e-02  -1.155  0.24993
## season10    -7.782e-02  6.567e-02  -1.185  0.23771
## season11    -6.007e-02  6.567e-02  -0.915  0.36171
## season12    -2.916e-02  6.568e-02  -0.444  0.65761
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1766 on 163 degrees of freedom
## Multiple R-squared:  0.3868, Adjusted R-squared:  0.3379
## F-statistic:  7.91 on 13 and 163 DF,  p-value: 4.097e-12
```

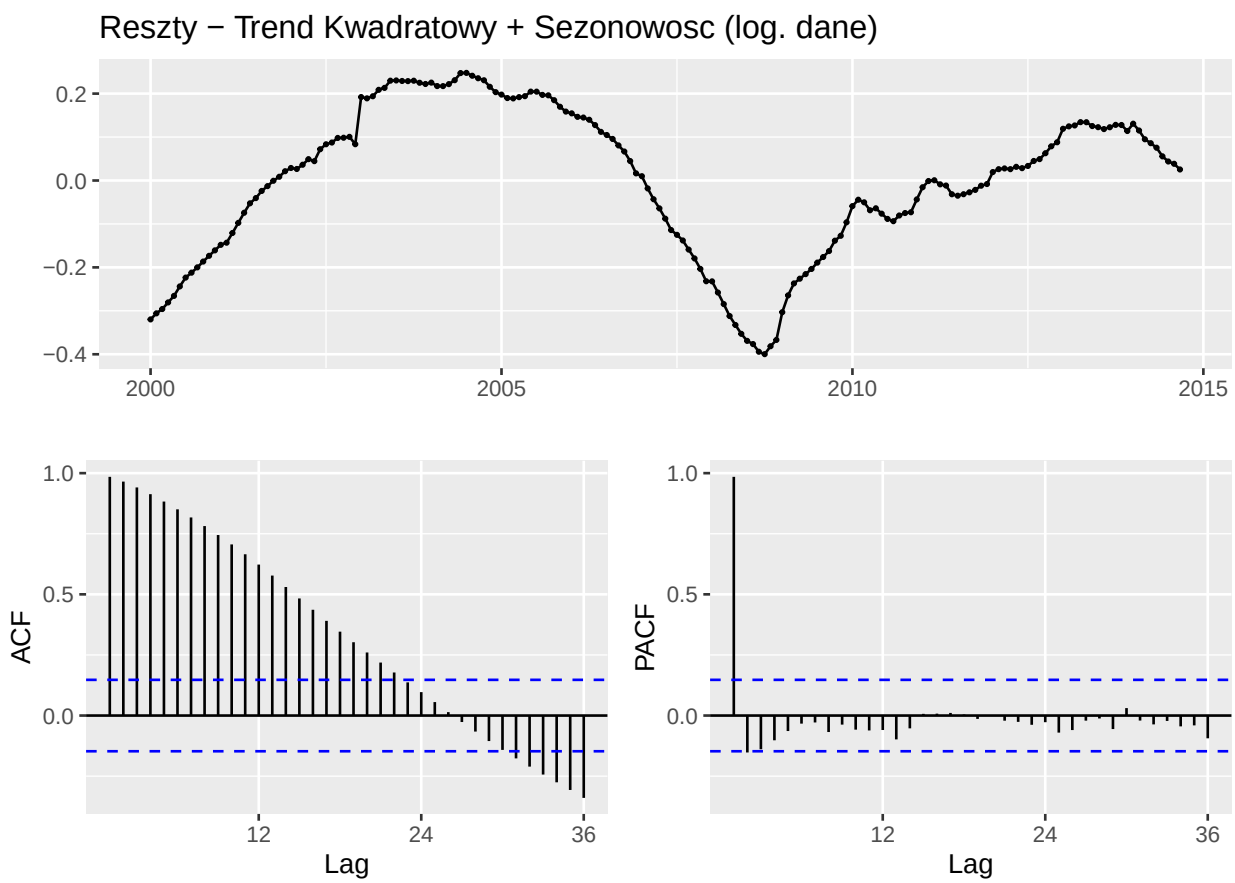

Rysunek 12: Reszty - trend kwadratowy + sezonowość (dane zlogarytmowane)

Wnioski z analizy TSLM:

Porównanie jakości dopasowania modeli

Model liniowy:

- $R^2 = 0.3974$
- skorygowane $R^2 = 0.3533$
- AIC = 847.2
- BIC = 891.67

Model kwadratowy:

- $R^2 = 0.3978$
- skorygowane $R^2 = 0.3498$
- AIC = 849.06
- BIC = 896.7

Test ANOVA porównujący modele zagnieżdżone

```
## Analysis of Variance Table
##
## Model 1: bezrobocie ~ trend + season
## Model 2: bezrobocie ~ trend + I(trend^2) + season
##   Res.Df    RSS Df Sum of Sq      F Pr(>F)
## 1    164 1060.5
## 2    163 1059.7  1   0.84161 0.1295 0.7195
```

- Mimo wyższego $R^2 = 0{,}3978$ dla modelu kwadratowego, skorygowane $R^2 = 0{,}3498$ oraz kryteria informacyjne (AIC/BIC) przemawiają na korzyść modelu liniowego, ponieważ nie oferuje on istotnej poprawy kosztem dodatkowego parametru.
  Wartości R^2 są relatywnie niskie (około 0,40, co oznacza, że modele regresyjne z prostymi trendami parametrycznymi nie wyjaśniają pełnej zmienności szeregu `bezrobocie`.
- Niskie wartości R^2 wynikają z faktu, że trend w tym szeregu jest wysoce nieregularny i nieliniowy, co utrudnia jego parametryczną aproksymację prostym wielomianem.
- Test ANOVA (p-value = 0,7195) wskazuje, że dodanie składnika kwadratowego do modelu jest statystycznie nieistotne, co potwierdza, że bardziej złożony model regresyjny nie jest uzasadniony.
- Transformacja logarytmiczna ($\lambda = 0$) nie poprawia znacząco jakości dopasowania, co potwierdza addytywny charakter szeregu oraz fakt, że optymalne λ jest bliskie 1 ($\lambda_{\text{opt}} = 1{,}02$).

Dekompozycja STL

Model z sezonowością okresową

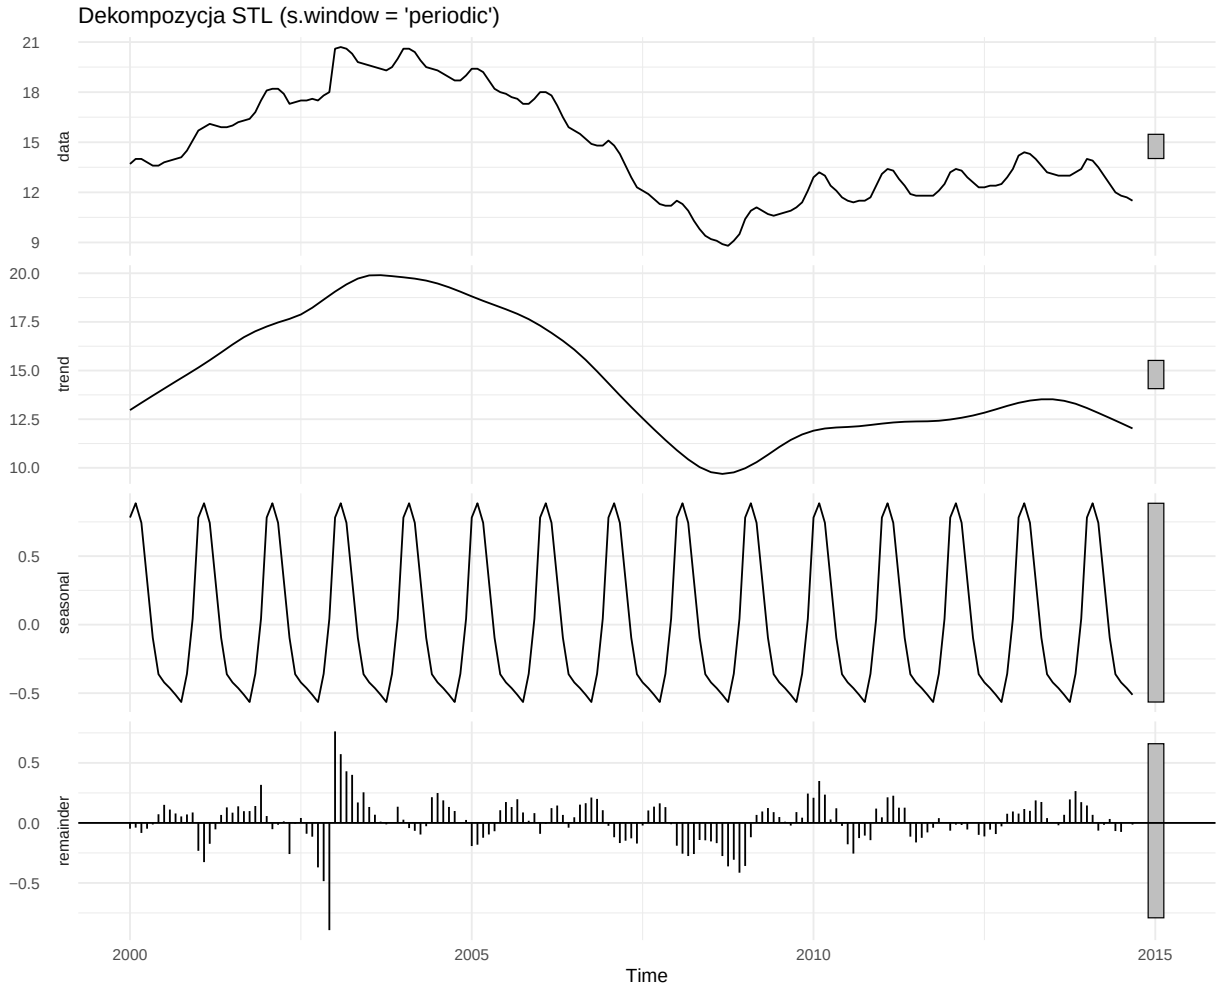

Rysunek 13: Dekompozycja STL - sezonowość okresowa

Model z sezonowością zmienną w czasie

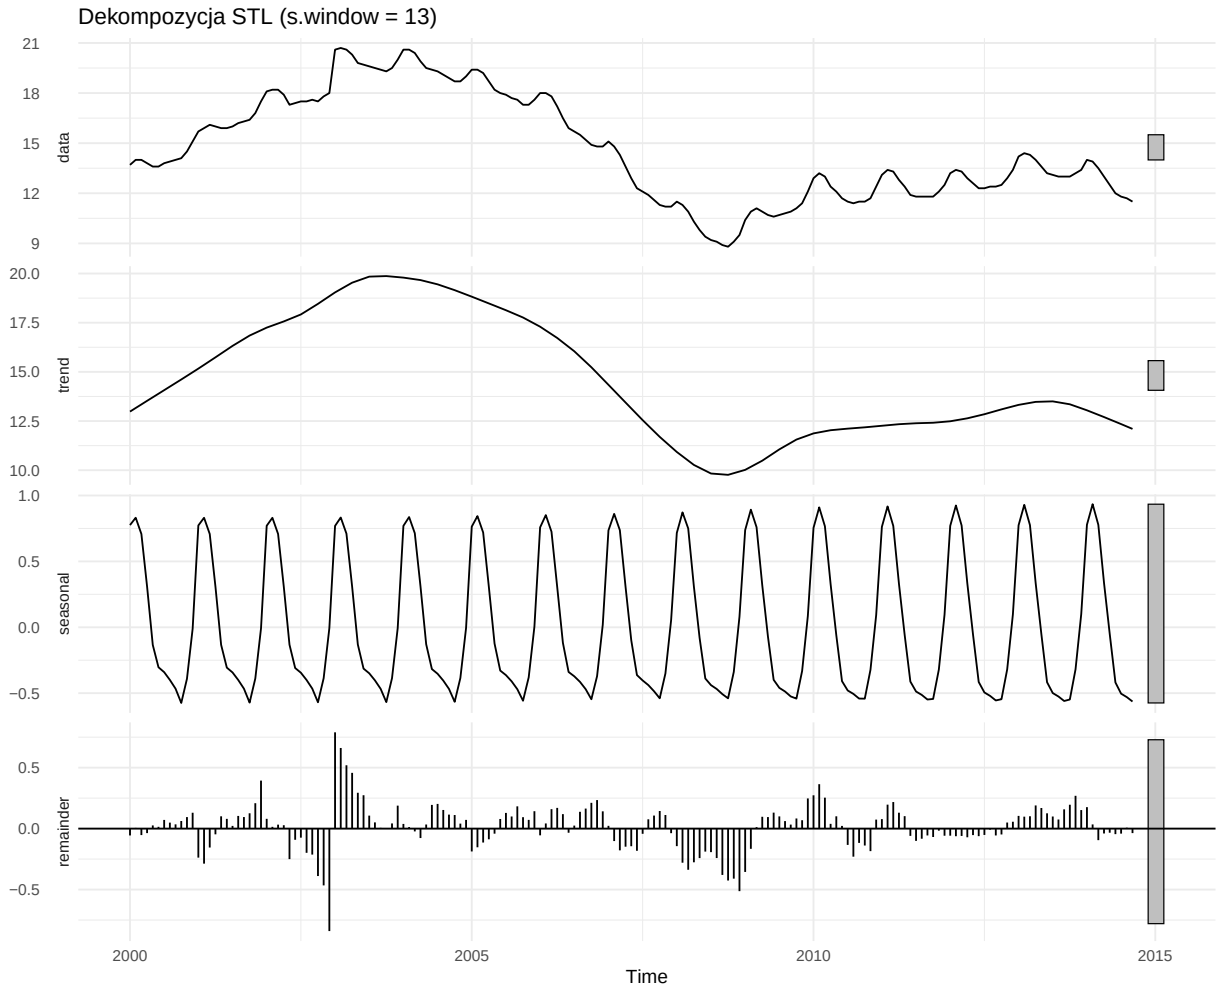

Rysunek 14: Dekompozycja STL - sezonowość zmienna

Model z silnym wygładzaniem trendu

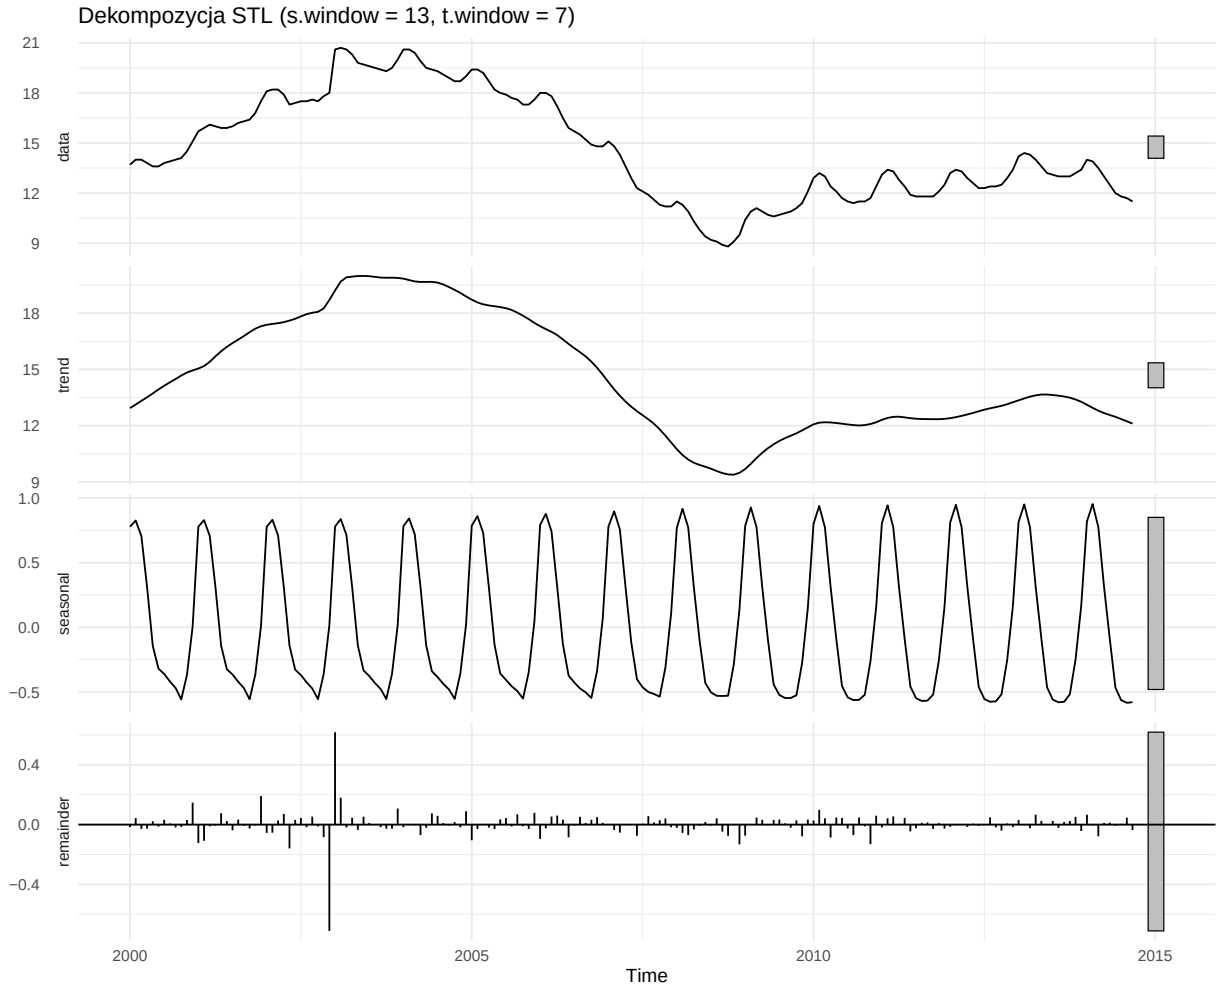

Rysunek 15: Dekompozycja STL - silne wygładzanie trendu

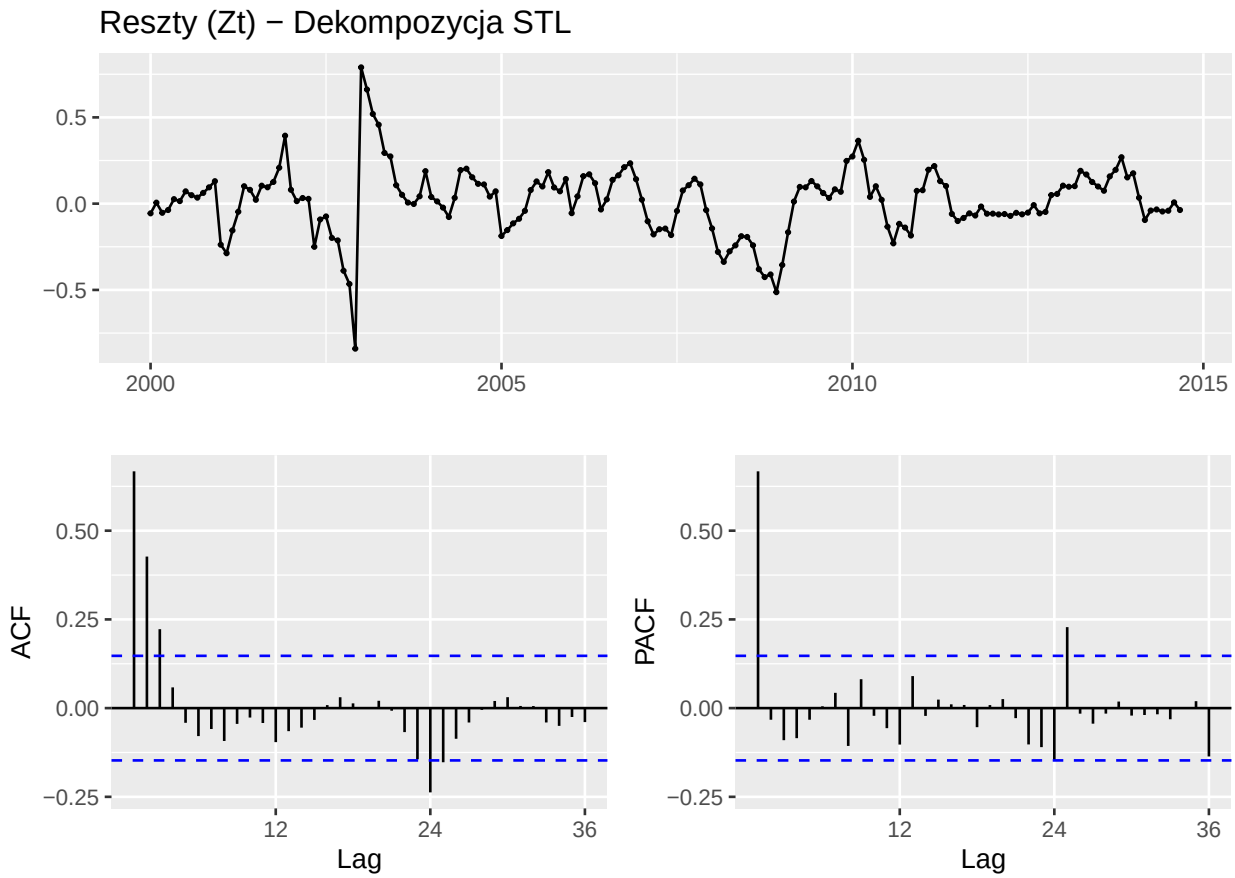

Rysunek 16: Reszty - dekompozycja STL

Wnioski dotyczące parametrów STL:

- Mniejsze wartości s.window i t.window pozwalają na szybsze zmiany odpowiednio składowej sezonowej i trendu.
- Model ze zmienną sezonowością (s.window = 13) może lepiej uchwyć ewentualne zmiany charakteru sezonowości w czasie.
- Metoda STL dobrze radzi sobie z nieregularnym trendem dzięki użyciu LOESS.

Eliminacja trendu i sezonowości przez różnicowanie

Różnicowanie sezonowe

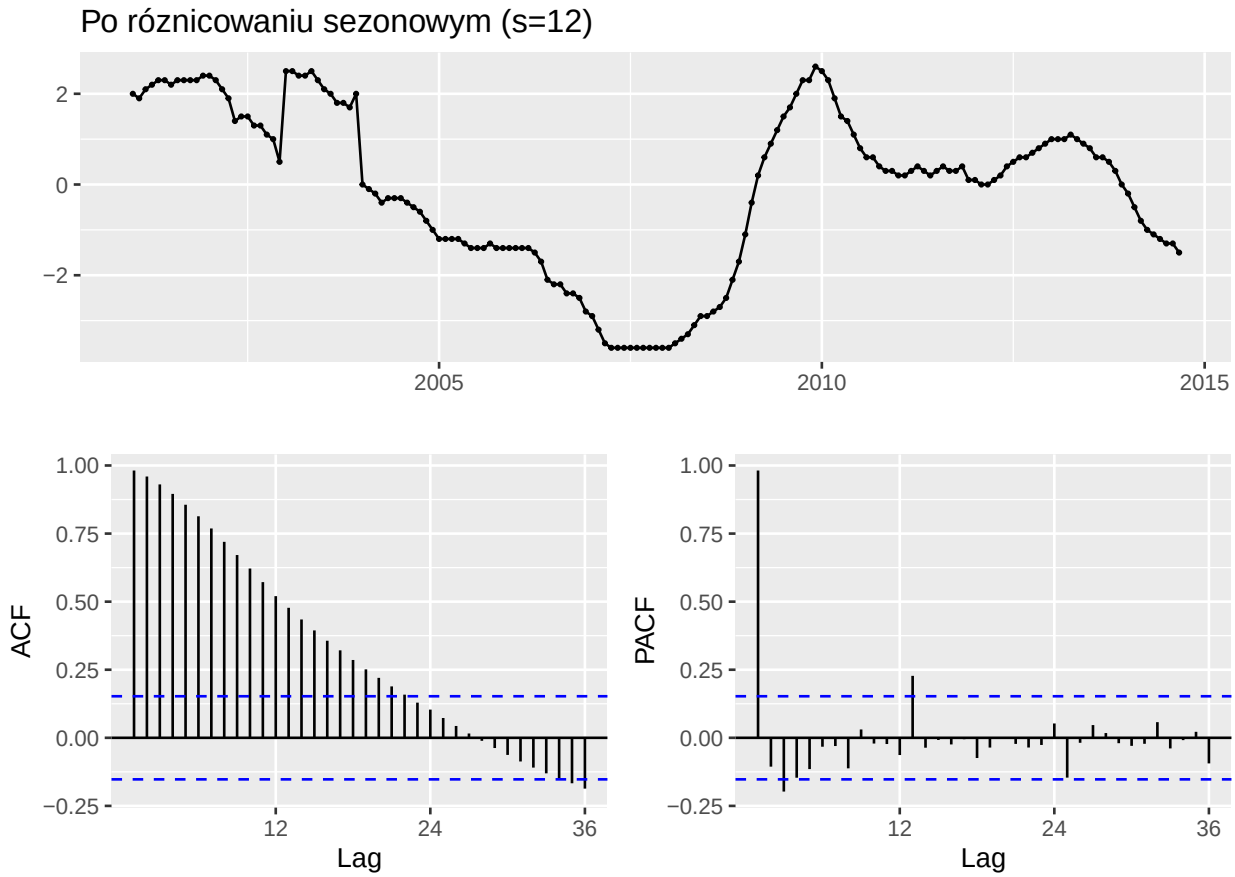

Rysunek 17: Szereg po różnicowaniu sezonowym

```
##
##  Box-Ljung test
##
## data:  bezrobocie_seas_diff
## X-squared = 1579.6, df = 41, p-value < 2.2e-16
```

Podwójne różnicowanie (sezonowe + zwykłe)

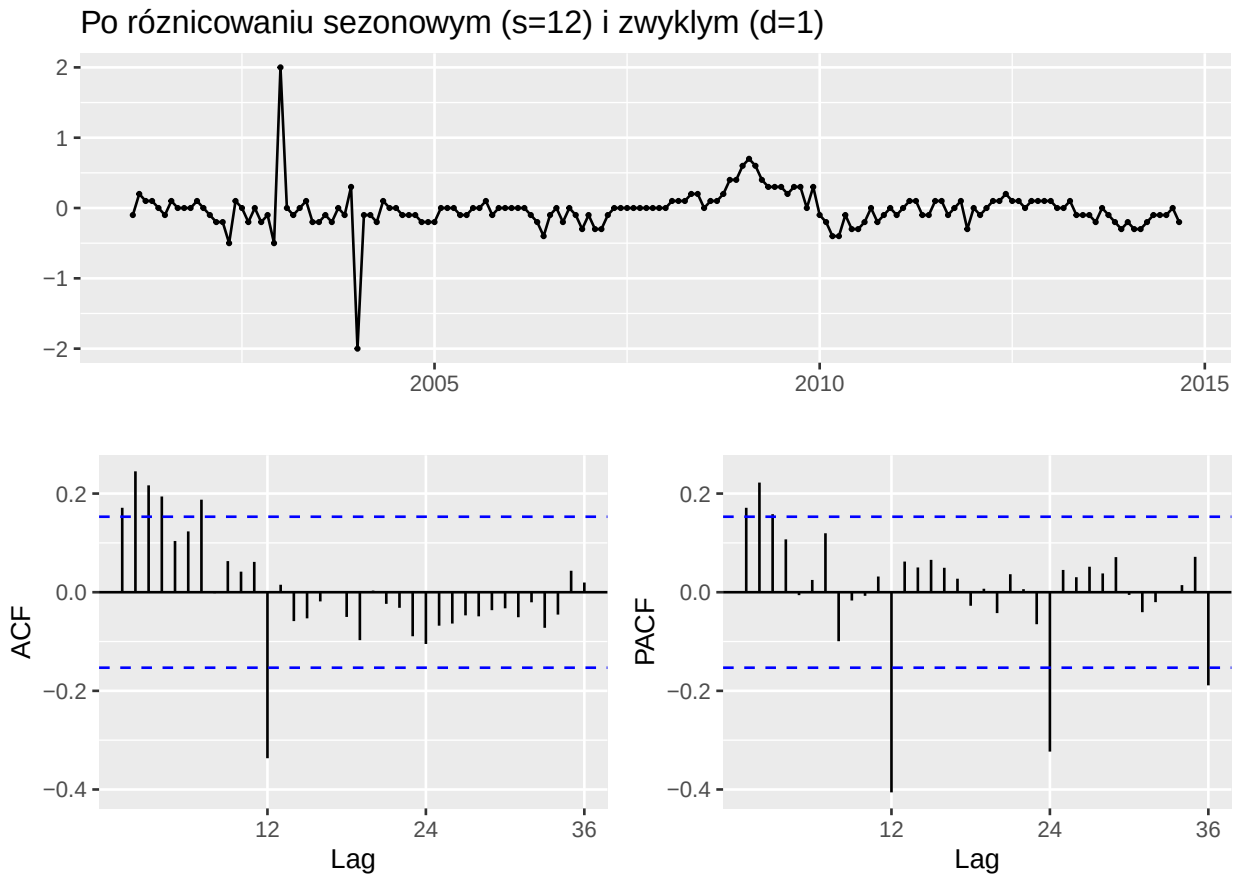

Rysunek 18: Szereg po podwójnym różnicowaniu

```
##
##  Box-Ljung test
##
## data:  bezrobocie_total_diff
## X-squared = 78.687, df = 41, p-value = 0.0003629
```

Porównanie wszystkich metod

Porównanie funkcji ACF

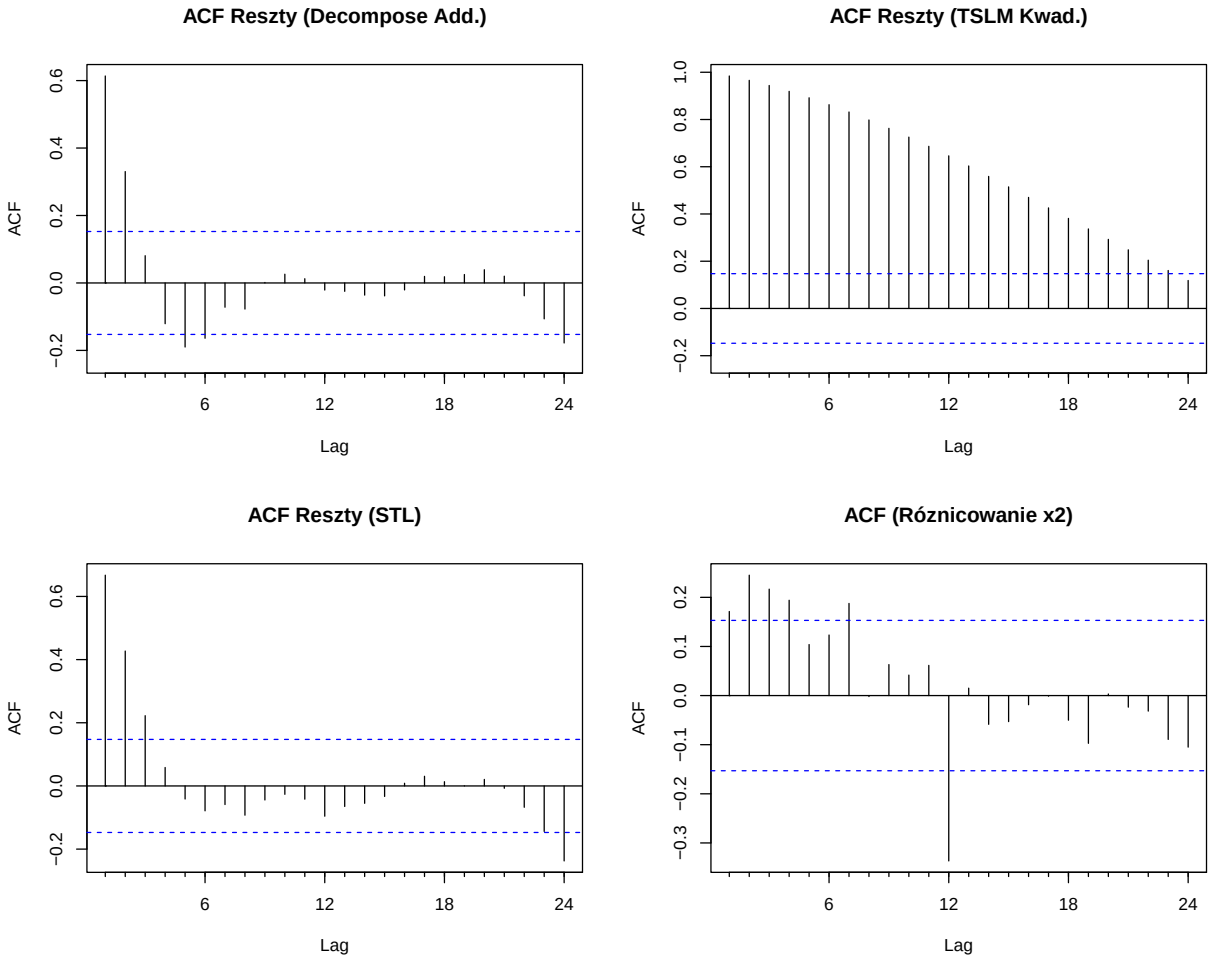

Statystyki porównawcze

Liczba parametrów w modelu TSLM (kwadratowy): 14

Wyniki testu Ljunga-Boxa dla różnych metod przekształcania szeregu

Tabela 1: Porównanie statystyk reszt dla różnych metod dekompozycji

Metoda	N	Wariancja	Odch. std.	MSE/Var(Y)	p-value (LB)	fitdf
Decompose (Add.)	165	0.0388	0.1970	0.0039	0e+00	0
TSLM (Kwad.)	177	6.0209	2.4538	0.6022	0e+00	14
STL	177	0.0377	0.1941	0.0038	0e+00	0

Różnicowanie (x2)	164	0.0843	0.2903	0.0084	1e-06	0

Interpretacja Tabeli:

1. Różnica w wariancji i elastyczności modelu

- **Różnica skali wariancji**:
  Wariancja reszt modelu TSLM ($\approx 6{,}02$) jest znacznie wyższa niż wariancja reszt metod Decompose ($\approx 0{,}04$) i STL ($\approx 0{,}04$).

- **Przyczyna**:
  `bezrobocie` charakteryzuje się nieregularnym trendem długoterminowym.
  ◦ Model TSLM z trendem wielomianowym (parametryczny) ma małą elastyczność i nie jest w stanie efektywnie dopasować się do nieregularnego trendu.
  ◦ Metody Decompose (oparta na ruchomej średniej) oraz STL (oparta na LOESS – lokalnie ważonej regresji wielomianowej) są metodami nieparametrycznymi, które lepiej dopasowują się do lokalnych, zmiennych trendów.

---

2. Względna miara wyjaśnionej zmienności (MSE/Var(Y))

- Miara MSE/Var(Y) określa ułamek niewyjaśnionej zmienności szeregu.

- Dla metod Decompose (addytywna) i STL, wskaźnik MSE/Var(Y) $\approx 0{,}004$, co oznacza, że te metody wyjaśniły ponad 99% zmienności szeregu (usuwając trend i sezonowość).

- Dla modelu TSLM (kwadratowego), wskaźnik MSE/Var(Y) $= 0{,}6022$, co oznacza, że model ten wyjaśnił jedynie około 40% zmienności ($1 - 0{,}6022 = 0{,}3978$).

---

3. Test Ljunga–Boxa

- Dla modelu TSLM zastosowano korektę stopni swobody uwzględniającą liczbę oszacowanych parametrów (fitdf $= 14$).

- Niskie wartości p-value $\leq 10^{-6}$ dla wszystkich metod wskazują, że resztowe szeregi nie są białym szumem.

- To oznacza, że w resztach pozostała słaba struktura zależności (autokorelacja), ale niekoniecznie świadczy o niepowodzeniu dekompozycji — ponieważ trend i sezonowość (składowe deterministyczne) zostały usunięte. Reszty powinny być teraz stacjonarnym szumem.

---

4. Najlepsza dekompozycja

- Metody STL i Decompose (addytywna) osiągnęły najniższą wariancję reszt (odpowiednio 0,0377 i 0,0388) oraz najwyższy współczynnik wyjaśnionej zmienności ($\approx$ 99,6%).
- Biorąc pod uwagę fakt, że STL najlepiej radzi sobie z nieregularnym trendem, jest ona uznawana za **optymalny wybór** dla `bezrobocie`.

Wnioski końcowe

Ocena jakości dekompozycji

Na podstawie przeprowadzonej analizy można sformułować następujące wnioski:

1. **Decompose (addytywna):** Daje bardzo dobre wyniki (wariancja reszt $\approx$ 0.0388), co potwierdza addytywny charakter szeregu — stabilną amplitudę sezonowości i wahań losowych. Metoda jest szybka i prosta w implementacji, a wyjaśnia ponad 99.6% zmienności szeregu.
2. **TSLM:** Najgorsze dopasowanie: wariancja reszt $\approx$ 6.02 i $R^2 \approx 0.40$, co oznacza wyjaśnienie jedynie około 40% zmienności szeregu. Trend wielomianowy jest zbyt mało elastyczny, by uchwycić nieregularne zmiany bezrobocia. Test ANOVA (p=0.7195) pokazuje, że człon kwadratowy nie poprawia istotnie modelu, a skorygowane R^2 (0.3498) jest niższe niż dla modelu liniowego (0.3533).
3. **STL:** Najbardziej elastyczna i najlepiej dopasowana metoda. Najniższa wariancja reszt ($\approx$ 0.0377) oznacza, że wyjaśnia ponad 99.6% zmienności. Reszty mają minimalną autokorelację, co świadczy o skutecznej izolacji trendu i sezonowości. STL jest też odporny na obserwacje odstające i pozwala na elastyczne dopasowanie do lokalnych zmian trendu dzięki metodzie LOESS.
4. **Różnicowanie:** Skutecznie usuwa niestacjonarność: po różnicowaniu sezonowym i zwykłym ACF szybko zanika (wariancja $\approx$ 0.0843, wyjaśnienie 99.2% zmienności). Wadą jest utrata interpretowalności składowych i konieczność odwracania operacji przy prognozowaniu.

Podsumowanie: STL jest najkorzystniejszą metodą dla tego szeregu: najlepiej uchwytuje nieliniowy trend i sezonowość, tworząc reszty o najniższej wariancji i niemal idealnej stacjonarności. Dodatkowo analiza potwierdza, że transformacja Boxa–Coxa nie jest potrzebna (optymalne $\lambda \approx 1.02$, blisko wartości addytywnego modelu).

Stacjonarność reszt

Szereg reszt można uznać za realizację szeregu stacjonarnego, jeśli:

- Brak regularnych wzorców (trendów, sezonowości)
- Wariancja jest jednorodna w czasie
- Funkcja ACF zanika szybko do zera

Rozstrzygnięcie stacjonarności: Na podstawie przeprowadzonej analizy:

- **Najniższą wariancję reszt** osiągnięto dla metod **decompose (addytywna)** i **STL** ($\approx 0.037 - 0.038$)
- **Najwyższy procent wyjaśnionej zmienności** (>99.6%): decompose i STL
- **STL** zapewnia najlepszą równowagę między jakością dekompozycji a elastycznością dopasowania do nieregularnego trendu
- **Różnicowanie** jest najbardziej skuteczne w eliminacji niestacjonarności (najszybciej zanikająca ACF), wyjaśnia 99.2% zmienności, ale kosztem utraty interpretacji składowych
- **TSLM** w tym przypadku jest najmniej efektywny - wariancja reszt ponad 150-krotnie wyższa niż decompose/STL, wyjaśnia jedynie około 40% zmienności

Uwaga o testach autokorelacji: Wszystkie metody wykazują niskie p-values w teście Ljung-Boxa (<0.001), co wskazuje na pozostałą słabą strukturę zależności. Nie dyskwalifikuje to metod dekompozycji - kluczowe jest:

- Usunięcie trendu i sezonowości (głównych źródeł niestacjonarności)
- Niska wariancja reszt - najlepsze dla decompose/STL
- Brak systematycznych wzorców w resztach
- Stabilna wariancja w czasie

Pozostała autokorelacja może wynikać z krótkoterminowych zależności nieprzechwyconych przez proste modele dekompozycji co jest typowe w rzeczywistych danych ekonomicznych.

Transformacja Box-Cox

Optymalne lambda bliskie 1 ($\lambda \approx 1{,}02$) oraz analiza reszt z modelu z transformacją logarytmiczną potwierdzają, że:

- Szereg bezrobocie ma charakter **addytywny** - amplituda wahań sezonowych nie zależy od poziomu szeregu
- Transformacja Box-Cox nie poprawia istotnie jakości dopasowania modeli

- W tym przypadku nie jest konieczne stosowanie transformacji stabilizującej wariancję
- Model z lambda=0 (logarytm) został przetestowany jedynie dla celów porównawczych, mimo że optymalne lambda nie wskazywało na konieczność transformacji

Praktyczna interpretacja: Dla szeregów z λ w przedziale [0.9, 1.1] nie ma zwykle istotnej różnicy między modelami addytywnymi a multiplikatywnymi, i preferujemy prostsze modele addytywne ze względu na łatwiejszą interpretację.

Wybór metody w praktyce

Wybór metody dekompozycji zależy od celu analizy i charakterystyki szeregu:

Gdy trend jest nieregularny (jak w przypadku bezrobocia):

- **Do analizy składowych i prognozowania:** STL (najlepsza elastyczność, LOESS dostosowuje się lokalnie, wariancja reszt ≈ 0.038)
- **Dla prostoty i szybkości:** decompose (addytywna) - prosta metoda dająca bardzo dobre wyniki (wariancja reszt ≈ 0.039)
- **Do eliminacji niestacjonarności przed modelowaniem ARIMA:** różnicowanie (najprostsza transformacja, ale bez bezpośredniej interpretacji składowych)
- **NIE zalecane:** TSLM - zbyt sztywny model dla nieregularnego trendu (wariancja reszt >150x wyższa, wyjaśnia tylko 40% zmienności)

Gdy trend jest regularny i można go aproksymować wielomianem:

- **TSLM** staje się użyteczny - łatwa ekstrapolacja i interpretacja parametrów
- Nadal warto porównać z metodami nieparametrycznymi jako benchmark

Ogólne zalecenia:

- Zawsze zaczynać od eksploracyjnej analizy graficznej (wykres szeregu, seasonplot, ACF)
- Testować transformację Box-Cox jeśli $\lambda \approx 1$, szereg jest addytywny
- Dla szeregów addytywnych preferować decompose lub STL
- Porównywać metody na podstawie wariancji reszt i procentu wyjaśnionej zmienności (1 - MSE/Var(Y))
- Sprawdzać reszty: wykresy, ACF, testy Ljung-Boxa z odpowiednim fitdf dla modeli parametrycznych

Dla *bezrobocie*: Optymalna metoda to **STL** lub **decompose (addytywna)**, które osiągają:

- Wariancję reszt <0.04 (TSLM: 6.02, tj. >150x gorzej)
- Wyjaśnienie >99.6% zmienności (TSLM: ~40%)
- Elastyczne dopasowanie do nieregularnego trendu bez konieczności specyfikacji parametrycznej postaci

Podsumowanie

Zadanie 3 - Kluczowe wnioski

1. **Test graficzny** (ACF) jest intuicyjnym narzędziem do szybkiej oceny białoszumowości, ale wymaga subiektywnej interpretacji.
2. **Testy formalne** (Box-Pierce, Ljung-Box) dostarczają obiektywnej, statystycznej oceny hipotezy o białoszumowości poprzez konkretną wartość p-value.
3. **Test Ljunga-Boxa** jest preferowany w praktyce ze względu na lepsze własności dla małych prób - jego empiryczny rozmiar jest bliższy nominalnemu poziomowi α=0.05, choć dla bardzo małych prób (n<=30) może wykazywać tendencję do liberalności.
4. **Test Boxa-Pierce'a** jest konserwatywny dla małych prób (zbyt rzadko odrzuca H_0), co obniża jego moc, ale zapewnia lepszą kontrolę błędu I rodzaju.
5. Oba podejścia (graficzne i formalne) są **komplementarne** i warto stosować je łącznie: najpierw analiza ACF/PACF dla rozpoznania typu zależności, następnie test formalny dla statystycznego potwierdzenia.
6. Wybór maksymalnego opóźnienia h_{max} ma istotny wpływ na wyniki testów - zalecana reguła to $h_{max} = \lfloor \ln(n) \rfloor$ lub $h_{max} = \lfloor n/4 \rfloor$ dla szeregów sezonowych.

Zadanie 4 - Kluczowe wnioski

1. ***bezrobocie*** charakteryzuje się nieregularnym trendem długoterminowym i wyraźną sezonowością roczną o charakterze addytywnym.
2. **Porównanie metod dekompozycji - jakość dopasowania:**
   - **STL i decompose (addytywna)**: najniższa wariancja reszt (( )0.037-0.038), wyjaśniają >99.6% zmienności
   - **Różnicowanie**: wariancja reszt $\approx$ 0.084, wyjaśnia 99.2% zmienności, najskuteczniejsze w eliminacji niestacjonarności, ale bez interpretacji składowych

- **TSLM**: $R^2 \approx 0.40$, wariancja reszt ≈ 6.02 (ponad 150x wyższa niż decompose/STL), wyjaśnia tylko około 40% zmienności
- **Ranking efektywności**: STL $\approx$ decompose (addytywna) $>$ różnicowanie » TSLM

3. **Przyczyny słabego dopasowania TSLM:**

   - Sztywna, parametryczna forma trendu (wielomian stopnia 1 lub 2) nie dopasowuje się do nieregularnego trendu bezrobocia
   - Model kwadratowy: mimo wyższego R^2 (0.3978), skorygowane R^2 (0.3498) jest **niższe** niż dla modelu liniowego (0.3533)
   - Test ANOVA (p=0.7195) potwierdza, że dodanie składnika kwadratowego jest statystycznie nieistotne
   - Kryteria informacyjne (AIC, BIC) również faworyzują prostszy model liniowy
   - Metody nieparametryczne (decompose, STL) są znacznie elastyczniejsze dla tego typu danych

4. **Transformacja Box-Cox:** Optymalne $\lambda \approx 1.02$ potwierdza addytywny charakter szeregu - transformacja nie poprawia jakości dopasowania.

5. **Testy autokorelacji reszt:**

   - Wszystkie metody wykazują pozostałą autokorelację (p-value <0.001 w teście Ljung-Boxa)
   - Dla TSLM zastosowano korektę fitdf=14 (liczba parametrów modelu)
   - Pozostała autokorelacja nie dyskwalifikuje metod dekompozycji - główne składowe (trend, sezonowość) zostały skutecznie usunięte, co potwierdzają niska wariancja reszt i brak systematycznych wzorców

6. **Rekomendacja:** Dla szeregu bezrobocie optymalne są metody **decompose (addytywna)** lub **STL** ze względu na:

   - Najwyższą efektywność wyjaśniania zmienności ($>99.6\%$)
   - Najniższą wariancję reszt (<0.04)
   - Elastyczne dopasowanie do nieregularnego trendu
   - STL ma dodatkową zaletę odporności na obserwacje odstające

Bibliografia i źródła

- Hyndman, R.J., & Athanasopoulos, G. (2018). *Forecasting: principles and practice*, 2nd edition, OTexts: Melbourne, Australia. OTexts.com/fpp2.
- Box, G. E. P., & Pierce, D. A. (1970). Distribution of residual autocorrelations in autoregressive-integrated moving average time series models. *Journal of the American Statistical Association*, 65(332), 1509-1526.
- Pakiet **forecast** dla R: Hyndman R, et al. (2023). forecast: Forecasting functions for time series and linear models. R package.
- Pakiet **TSAFBook**: Materiały do zajęć z Analizy Szeregów Czasowych, Politechnika Wrocławska. (Analiza i prognozowanie szeregów czasowych. Praktyczne wprowadzenie na podstawie środowiska R", A. Zagdański, A. Suchwałko, PWN, 2015, ISBN 978-83--01-18356-1)